

Detección temprana de pedidos anómalos de clientes mediante predicción de referencia y árboles de decisión

Proyecto de Fin de Carrera I — Informe de avance

Sefora Cieza Lujan

Universidad de Ingeniería y Tecnología (UTEC)

sefora.cieza@utec.edu.pe

4 de octubre de 2026

Resumen

Bimbo despacha a 61 tiendas Bembos lo que el sistema de compras del cliente le indica, sin ninguna validación previa de que esa cantidad tenga sentido. Cuando la tienda se equivoca al registrar el pedido, el error se convierte en producto despachado. Este informe delimita ese problema sobre 10 374 líneas de pedido vigentes y propone un software que compare cada pedido con el historial de su tienda y explique por qué lo marca. Tras comparar cuatro alternativas, se selecciona la validación con el historial por ser la única que no requiere cambios en el cliente y que permite justificar cada alerta. Se presentan la estructura del trabajo, el cronograma, un presupuesto preliminar de S/ 5 256 con reservas, los riesgos y los indicadores del proyecto. El avance de las semanas 1 a 6 incluye un prototipo que procesa el archivo original y mide reglas sencillas. Con información de semanas completas, la mejor regla acierta en el 45 % de sus alertas; al limitarla a lo que se sabe en el momento de alertar, como recomendó el asesor, ese valor cae a entre 6 % y 17 %. Aun así, el único error confirmado se detecta entre tres y cinco días antes de la entrega. Estos resultados son preliminares y se validarán con casos confirmados y un periodo de evaluación independiente.

Índice

1. El problema	4
1.1. Cómo funciona hoy la operación	4
1.2. Lo que dijeron y lo que realmente pasa	4
1.3. Por qué pasa: cinco porqués	4
1.4. Ishikawa	5
1.5. La evidencia	5
1.6. El conjunto de datos	5
1.6.1. Diccionario de columnas	7
1.7. Qué dicen los datos	7
1.7.1. Las líneas anuladas y el doble pedido	7
1.7.2. El método encuentra el caso que ya conocíamos	9
1.7.3. Cuánto producto se despacha de más	9
1.7.4. El feriado también levanta los pedidos	10
1.7.5. Separar la campaña del error sin preguntarle a nadie	10

1.7.6.	Los parámetros del método	11
1.7.7.	Cuántas alertas serían	12
1.8.	A quién le duele	12
1.9.	Los stakeholders y quién decide	12
2.	La solución	13
2.1.	La propuesta	13
2.2.	Por qué el proyecto se limita a estos datos	14
2.3.	Cómo funciona	14
2.4.	Con qué variables decide el árbol	14
2.5.	De dónde sale la etiqueta	15
2.6.	Contra qué se compara	15
2.7.	El pedido que no llegó	15
2.8.	El software	16
2.8.1.	Cargar el archivo	16
2.8.2.	Revisar las alertas	16
2.8.3.	Ver lo que no llegó	17
2.8.4.	Exportar	17
2.8.5.	Cómo está construido	17
2.9.	Objetivo	17
2.10.	Objetivos específicos	18
3.	Alcance y verificación	18
3.1.	Qué entra y qué no	18
3.2.	Restricciones, supuestos e incertidumbres	20
3.3.	Qué se va a medir	20
3.4.	Criterios de aceptación del prototipo	20
3.5.	Viabilidad	21
3.6.	Plan de trabajo	22
4.	Propuesta de solución	23
4.1.	Alternativas identificadas	23
4.2.	Criterios de selección	24
4.3.	Solución seleccionada y prototipo previo	24
4.4.	Estructura de desglose del trabajo	24
4.5.	Paquetes de trabajo	24
4.6.	Entregables y criterios de aceptación	24
4.7.	Resultados esperados	26
5.	Cronograma	26
5.1.	Diagrama de Gantt preliminar	26

5.2. Identificación de hitos	26
6. Presupuesto	28
6.1. Estimación preliminar de costos	28
6.2. Supuestos utilizados	28
7. Riesgos	29
7.1. Lista preliminar de riesgos	29
7.2. Matriz de probabilidad e impacto	29
7.3. Estrategias de respuesta	29
8. Indicadores	30
9. Retroalimentación incorporada	30
9.1. Segunda revisión del asesor	32
10. Avance del proyecto: semanas 3 a 6	32
10.1. Retroalimentación del asesor y cómo se incorpora	32
10.1.1. Qué información existe en el momento de alertar	32
10.1.2. Desviación, caso sospechoso y error confirmado	33
10.1.3. Del análisis semanal a la alerta por pedido	33
10.1.4. Periodos de ajuste, validación y prueba	34
10.2. Resumen del estado del proyecto	34
10.3. Revisión de la limpieza de datos	34
10.4. Paso 2: la tabla de señales	35
10.5. Paso 3: casos sospechosos y su validación	36
10.6. Paso 4: el punto de partida que el modelo debe superar	37
10.7. Primera versión por pedido	39
10.8. La brecha y la hipótesis de trabajo	40
10.9. Aprendizaje sobre la forma de trabajar	40
10.10 Síntesis	40
A. Evidencias del prototipo	41
A.1. Archivo de entrada	42
A.2. Paso 1: limpieza	42
A.3. Paso 2: señales	43
A.4. Paso 3: casos sospechosos	44
A.5. Paso 4: reglas sencillas	44
A.6. Versión por pedido	45

1. El problema

1.1. Cómo funciona hoy la operación

Bimbo abastece de pan de hamburguesa a las tiendas Bembos, operadas por NGR y EyH. Cada tienda calcula lo que va a necesitar, el área de compras consolida esas necesidades y emite una orden de compra en el ERP. El proveedor produce y despacha contra esa orden, y factura a 60 días.

Todo el proceso descansa en un supuesto que nadie verifica: que la cantidad escrita en la orden es la cantidad correcta. Si una tienda registra 432 unidades donde quería 108, el sistema no lo cuestiona. El único filtro es que alguien del proveedor abra el archivo, note algo raro y escriba un correo preguntando.

1.2. Lo que dijeron y lo que realmente pasa

La queja llegó así, con estas palabras: «observo cantidades altas en pedido de las tres presentaciones, como ejemplo de doble pedido de algunas tiendas». A continuación se separan el síntoma, el problema y la solución que suele proponerse primero.

Tabla 1: Separación entre lo que se ve, lo que falla y la solución precipitada.

Síntoma	Problema	Solución que aparece primero
Llegan pedidos con cantidades muy por encima de lo habitual, y a veces la misma línea repetida	No existe ningún control que compare la cantidad pedida contra el comportamiento histórico de esa tienda antes de que el pedido se despache	Que alguien revise el archivo todos los días o que el ERP tenga un tope

La revisión manual del archivo ya se realiza y no es suficiente, y un tope fijo trataría igual a una tienda de centro comercial y a una de barrio. Lo que falta es un criterio automático basado en el historial de cada tienda.

1.3. Por qué pasa: cinco porqués

1. **¿Por qué se despachan pedidos con cantidades erróneas?** Porque el proveedor produce contra lo que dice la orden de compra.
2. **¿Por qué produce contra una orden que puede estar mal?** Porque no tiene forma de saber que lo está antes de producir.
3. **¿Por qué no tiene forma de saberlo?** Porque la única revisión es visual y depende de que un analista reconozca el patrón en un archivo de cientos de líneas.
4. **¿Por qué la revisión es visual?** Porque no hay un valor de referencia calculado contra el cual comparar cada línea.
5. **¿Por qué no hay valor de referencia?** Porque el historial de pedidos por tienda y producto existe en el sistema pero nunca se ha usado para construir uno. **Esa es la causa raíz.**

Si se elimina esta causa, la comparación deja de depender de la revisión visual de una persona.

1.4. Ishikawa

Los cinco porqués siguen una sola cadena. El diagrama de causa-efecto de la Figura 1 abre esa cadena en las seis familias de causas que suelen revisarse en una operación, para comprobar que no queda ninguna fuera.




Figura 1: Diagrama de causa-efecto sobre el despacho de pedidos con cantidad errónea [8]. Las causas de Sistemas y Mediciones son las que este proyecto ataca; las de Entorno explican los falsos positivos que el modelo debe evitar.

1.5. La evidencia

Tres correos de la operación sostienen lo anterior. El primero (Figura 2) es el mensaje interno que originó la revisión: advierte cantidades altas en las tres presentaciones, con doble pedido en varias tiendas.

Los otros dos muestran el control actual funcionando y fallando. En el segundo, el proveedor avisa que la tienda de ATE tiene un pedido «muy alto en comparación a su despacho anterior y el posterior» y recuerda que las alertas se responden en 30 minutos. El criterio que usa la analista es comparar contra el periodo anterior, que es lo que este proyecto busca automatizar.

En el tercero, nadie contestó dentro de la ventana y el pedido se despachó igual, para no desabastecer la tienda. Es decir, el control existe, pero no detiene el despacho.

1.6. El conjunto de datos

El proyecto trabaja sobre un conjunto de datos real: el archivo `exportBIMBO.xlsx`, exportado del sistema de compras del cliente. Es la misma exportación que el área de planeamiento genera de forma rutinaria para revisar los pedidos, de modo que no hubo que construir nada para obtenerlo ni habrá que cambiar nada para volver a obtenerlo.

Cada fila del archivo es una *línea de pedido*: un producto solicitado por una tienda para una fecha de entrega, dentro de una orden de compra. Una orden agrupa varias líneas, identificadas por su número de posición. El archivo tiene 10 772 filas y 28 columnas, y cubre del 1 de julio al 11 de septiembre de 2026.



Figura 2: Comunicación interna que reporta cantidades altas y doble pedido en las tres presentaciones de pan de hamburguesa.




Figura 3: Alerta manual del proveedor sobre el pedido atípico de una tienda, comparado contra el despacho anterior y el posterior.

Tabla 2: Muestra de las primeras filas del archivo.

Fe. entrega	Orden	Pos.	Material	Tienda	Cantidad	Valor S/
11-09-2026	4500730889	10	201985	BB TDA MONTERRICO	180	125,40
11-09-2026	4500730889	20	201986	BB TDA MONTERRICO	330	193,60
11-09-2026	4500730889	30	201987	BB TDA MONTERRICO	480	238,40
11-09-2026	4500730889	40	201985	BB TDA AURORA	144	100,32
11-09-2026	4500730889	50	201986	BB TDA AURORA	420	246,40
11-09-2026	4500730889	60	201987	BB TDA AURORA	420	208,60




Figura 4: Sin respuesta dentro de la ventana, el pedido sospechoso se atiende de todos modos.

1.6.1. Diccionario de columnas

De las 28 columnas, 12 aportan información al análisis, 12 son constantes o administrativas y 4 vienen completamente vacías. La Tabla 3 las describe.

Tres observaciones sobre la calidad del archivo condicionan el análisis. La unidad de medida es única (UN) en todas las filas, de modo que no hay que convertir entre bolsas, bandejas y unidades dentro de este extracto. El campo de facturación está presente solo en 6 926 filas, porque las órdenes más recientes aún no se facturan, así que no sirve para verificar lo entregado. Y el indicador de borrado obliga a un filtro previo que se explica en la Sección 1.7.1.

Con los tres campos clave, que son tienda, material y fecha de entrega, más la cantidad, el archivo se reorganiza en 180 series semanales de tienda y producto, que son la materia prima del método. De ellas, 176 tienen suficiente historial previo para poder evaluarse, lo que deja 1 554 observaciones de tienda, producto y semana sobre las que se mide todo lo que sigue.

1.7. Qué dicen los datos

Los correos describen el fenómeno; el extracto del sistema de compras permite medirlo. Las cifras de esta sección tienen el siguiente alcance. Las cifras y figuras de esta sección provienen de un análisis exploratorio *ya ejecutado* sobre el extracto real, con un cuaderno en Python que se vuelve a correr sobre cualquier archivo del mismo formato. No son estimaciones ni ejemplos ilustrativos. Lo que todavía no existe es el software descrito en la Sección 2.8: el método está probado, la herramienta que lo pone en manos de quien revisa está por construirse. Por tanto, estos resultados son un primer indicio de que el enfoque puede funcionar con los datos históricos; no son una medición del sistema en operación ni han sido validados en un periodo independiente (Sección 10.1.4).

1.7.1. Las líneas anuladas y el doble pedido

Entre las columnas del archivo hay una llamada *indicador de borrado*. Está vacía casi siempre, pero en 398 líneas dice «L», la marca que usa el sistema cuando una posición se elimina. Estas líneas modifican los conteos, por lo que se analizaron por separado.

Tabla 3: Columnas del archivo, su contenido y su uso en el proyecto.

Columna	Contenido	Valores distintos	Uso
Fecha documento	Día en que se registró la orden	30	Contexto
Fe. Entrega	Día comprometido de entrega	68	Clave
Documento compras	Número de orden de compra	156	Agrupación
Posición	Número de línea dentro de la orden	197	Duplicidad
Material	Código del producto	3	Clave
Texto breve	Descripción del producto	3	Reporte
Tienda	Nombre de la tienda solicitante	61	Clave
Centro	Código de la tienda	61	Equivale a Tienda
Cantidad de pedido	Unidades solicitadas	115	Variable objetivo
Cantidad en UMA	Igual a la anterior en este extracto	115	Verificación
Por entregar (cantidad)	Pendiente de despacho	61	Contexto
Valor neto de pedido	Importe de la línea en soles	196	Costo del exceso
Precio neto	Precio de referencia del producto	59	Contexto
Indicador de borrado	Marca «L» si la línea fue eliminada	1	Filtro
Creado por	Usuario que registró la orden	23	Contexto
Nombre del proveedor	Razón social del proveedor	7	Filtro
N.º Factura, Ref. Sunat, Fecha Pago	Datos de facturación, presentes en 6 926 filas	–	No se usan
Unidad medida pedido, Unidad de almacén, Moneda, Grupo de artículos, Cantidad base	Constantes en todo el archivo	1	No aportan
Historial pedido, Número de necesidad, Num. EM o AC, Tipo de imputación	Columnas vacías en las 10 772 filas	0	No se usan

De esas 398 líneas anuladas, 385 tienen al menos una línea activa para la misma tienda, el mismo producto y la misma fecha de entrega. No son pedidos adicionales: son pedidos que se borraron y se volvieron a cargar. Al comparar cada anulada con su reemplazo, en la enorme mayoría de los casos la cantidad es idéntica, es decir que se volvió a cargar exactamente lo mismo, y solo en 27 la cantidad cambió, con la versión definitiva mayor en 19 casos y menor en 8.

Esto obliga a trabajar con las 10 374 líneas vigentes, y corrige una cuenta que sin ese filtro sale mal. Si se dejan las anuladas junto con sus reemplazos, el archivo aparenta tener cientos de pedidos repetidos con la misma cantidad, cuando en realidad se está contando dos veces el mismo pedido. Descontándolas quedan **54 casos de cantidad idéntica repetida**, que suman 119 líneas, y 176 combinaciones de tienda, producto y fecha con más de una línea. Ese es el volumen real del doble pedido, y para encontrarlo no hace falta ningún modelo: alcanza con una consulta.

Las líneas donde la corrección cambió la cantidad (23 con el criterio de emparejamiento de la Sección 10.3) son pedidos que alguien registró de una forma y después modificó. No se consideran errores por sí mismas, porque una modificación puede responder a una necesidad legítima de la tienda; se tratan como casos sospechosos que requieren evidencia (Sección 10.5).

1.7.2. El método encuentra el caso que ya conocíamos

Se calculó, para cada tienda y producto, la mediana de las cuatro semanas previas como valor de referencia $\hat{q}_t$, y la diferencia relativa contra el pedido real, $e_t = (q_t - \hat{q}_t)/\hat{q}_t$. La Figura 5 muestra qué pasa con la tienda de ATE en pan grande.

Esa semana marcada es el pedido del sábado 22 de agosto, el mismo que motivó el correo de la Figura 3. El cálculo llegó a la misma conclusión que la analista, sin que nadie le indicara qué buscar. Es un indicio de que el criterio automático puede coincidir con el juicio de la analista, aunque se basa en un solo caso confirmado.




Figura 5: Tienda ATE, pan grande: pedido real contra valor de referencia. La semana del 17 de agosto pide 432 unidades donde se esperaban 117.

1.7.3. Cuánto producto se despacha de más

El impacto no está en la merma de la tienda sino en el propio despacho: se produce, se transporta y se factura una cantidad que el cliente no pidió realmente. Con el precio unitario

implícito en cada línea (mediana S/ 0,59) se puede poner número a ese exceso.

Tabla 4: Exceso despachado sobre el valor de referencia, umbral $\tau = 0,8$.

Desviaciones detectadas en 9 semanas evaluables	17
Exceso acumulado (unidades)	11 200
Exceso acumulado (S/)	6 625
Valor potencial en riesgo al mes (S/)	3 187

Alrededor de **S/ 3 200 al mes** de *valor potencial en riesgo*: el valor del producto que se habría despachado por encima de lo esperado si todas estas desviaciones fueran errores. No es una pérdida comprobada; la pérdida efectiva dependerá de cuántas desviaciones se confirmen como error (Sección 10.1.2). La cifra descuenta el movimiento común de la cadena, según el procedimiento de la Sección 1.7.5, y excluye las líneas anuladas.

1.7.4. El feriado también levanta los pedidos

No todas las alzas son errores. La semana del 27 de julio, Fiestas Patrias, llega al 12,4 % de series con alza superior al 50 %, frente a un nivel de fondo cercano al 2 %. Una regla de umbral marcaría veinte tiendas esa semana, todas correctas, y el analista dejaría de mirar las alertas en poco tiempo. Distinguir el feriado del error exige una pregunta que ningún umbral sobre una sola variable puede responder: si la tienda subió sola o subió junto con todas las demás. La Sección 1.7.5 la responde con los datos.

1.7.5. Separar la campaña del error sin preguntarle a nadie

Un error de digitación de una tienda no mueve el promedio de las otras 175 series; un feriado sí. Sobre esa diferencia se puede construir un criterio que distinga ambos casos con los datos disponibles, sin depender de que alguien recuerde qué ocurrió una semana determinada.

Se define un *factor común semanal* a_t como la mediana del residuo de todas las series esa semana, y se descompone

$$e_t = \underbrace{a_t}_{\text{lo que le pasó a todo el universo}} + \underbrace{u_t}_{\text{lo que le pasó solo a esta tienda}}.$$

La decisión de anomalía se toma sobre u_t .

La semana con mayor movimiento conjunto es la del 27 de julio, Fiestas Patrias, con un factor común de +0,114. Tres señales permiten separarla del caso de ATE, que es un error confirmado por correo.

Tabla 5: Firma de una semana de campaña frente a la de un error de captura.

Señal	27-jul (Fiestas Patrias)	17-ago (caso ATE)
Factor común a_t	+0,114	−0,117
Series en alza, sin corregir	12,4 %	2,8 %
Series en alza, corregido	7,7 %	3,4 %
Tiendas que suben en las 3 presentaciones	8 de 57	0 de 60
Residuo mediano la semana siguiente	+0,01	+0,71

Las dos últimas filas son las que más separan un caso del otro, pero la última usa información de la semana siguiente; por eso solo sirve para el análisis retrospectivo y no se usa para emitir




Figura 6: Arriba, el factor común semanal. Las dos semanas de julio que lo superan corresponden a movimientos de toda la cadena. Abajo, el porcentaje de series en alza antes y después de descontar ese factor.

alertas (Sección 10.1.1). En Fiestas Patrias suben las tres presentaciones a la vez en varias tiendas y el efecto se agota la semana siguiente, que vuelve a su nivel normal. En ATE ninguna tienda movió las tres presentaciones y el residuo sigue alto siete días después, que es el comportamiento esperable de un error arrastrado y no de un pico de consumo.

1.7.6. Los parámetros del método

El procedimiento no depende de un juicio externo, pero sí de cinco parámetros que deben ajustarse con validación temporal en lugar de fijarlos a ojo.

Tabla 6: Hiperparámetros del detector.

Símbolo	Qué controla	Valor inicial	Cómo se ajusta
k	Semanas de historial para la mediana de referencia	4	Error de predicción contra persistencia
τ	Cuánto tiene que desviarse una tienda por su cuenta (u_t) para marcar la línea	0,8	Precisión contra carga de alertas
κ	Factor común a partir del cual la semana se declara de campaña	0,10	Semanas conocidas de feriado
σ	Presentaciones que deben subir juntas para atenuar la alerta	2 de 3	Casos marcados como error
ρ	Reversión esperada la semana siguiente para confirmar campaña	0,00	Solo análisis retrospectivo (usa la semana siguiente)

Dejar la pregunta resuelta como parámetro y no como consulta tiene una ventaja sobre preguntar: el método vuelve a clasificar correctamente la próxima semana atípica sin que nadie tenga que recordar qué pasó en esta.

1.7.7. Cuántas alertas serían




Figura 7: Alertas semanales esperadas según el umbral sobre u_t . Con $\tau = 0,8$ salen unas 2 por semana.

Dos alertas por semana caben sin problema en la ventana de 30 minutos que ya está pactada. Un umbral más bajo detectaría más errores, pero generaría más alertas de las que el área puede revisar.

1.8. A quién le duele

Tabla 7: Matriz impacto–interesados.

Interesado	Cómo le afecta hoy	Magnitud al mes	Evidencia
Proveedor (Bimbo)	Produce, transporta y factura una cantidad distinta de la que el cliente realmente necesitaba	$\approx$ S/ 3 200 en riesgo (potencial)	Tabla 4
Planeamiento (Bimbo)	Revisa el archivo línea por línea y redacta los correos de confirmación	17 casos por revisar cada 9 semanas	Figura 3
Compras (NGR)	Recibe la alerta, verifica con la tienda y rectifica la orden	23 líneas modificadas en el extracto	Indicador de borrado
Tiendas	Reciben una cantidad que no corresponde a su pedido	54 casos de cantidad repetida	Sección 1.7.1
Producción (Bimbo)	Planifica sobre una señal de demanda distorsionada	Indirecta	Efecto conocido en cadenas de suministro [9]

1.9. Los stakeholders y quién decide

Responsable del resultado: Sefora Cieza Lujan, autora del proyecto. Lo ejecuta de principio a fin: la preparación de los datos, el marcado de los casos, el modelo y el software. La

Tabla 8: Ubicación de los interesados según poder e interés.

Interesado	Cuadrante	Qué necesita	Frecuencia
Jefatura de planeamiento (Bimbo)	Alto poder, alto interés	Que las alertas bajen su carga manual y sean defendibles ante el cliente	Semanal
Analista de planeamiento	Bajo poder formal, alto interés	Que el reporte llegue antes del cierre del pedido y no le sume trabajo	Semanal
Compras (NGR)	Alto poder, interés medio	Que la alerta no frene un pedido legítimo	Quincenal
Tiendas	Bajo poder, alto interés	No quedar desabastecidas por una alerta mal disparada	Por excepción
TI del cliente	Alto poder, bajo interés	Que nada de esto exija tocar el ERP en esta etapa	Por hito

jefatura recibe el resultado al cierre y el asesor aprueba el entregable académico, pero ninguna etapa intermedia depende de que un tercero responda.

Tabla 9: Responsabilidades sobre los entregables (RACI).

Actividad	Practicante	Asesor	Jefatura	Cliente
Preparación y limpieza de datos	R/A	I	I	I
Marcado de los casos que fueron error	R/A	C	I	I
Construcción y validación del modelo	R/A	C	I	I
Calibración del umbral de alerta	R/A	C	I	I
Construcción del software	R/A	I	I	I
Presentación de resultados a la empresa	R	I	A	I
Aprobación del entregable académico	R	A	I	I

2. La solución

2.1. La propuesta

La solución es un software de validación de pedidos. Quien revisa los pedidos carga el Excel que ya exporta del sistema de compras y el programa devuelve otro con los productos cuyo pedido no coincide con lo que el historial del cliente permitía esperar. En lugar de revisar miles de líneas una por una, el analista revisa solo las que quedan marcadas. El programa no reemplaza la decisión: para cada producto marcado indica cuánto pidió la tienda, cuánto se esperaba según sus semanas anteriores y por qué se marcó, de modo que esa misma fila sirva para reclamarle al cliente. La confirmación final sigue siendo humana.

Se consideraron otras dos opciones más directas, que se descartaron. Un tope fijo de cantidad en el ERP trataría igual a una tienda de centro comercial que a una de barrio, y exigiría modificar un sistema que no controlamos. Pedir a las tiendas que confirmen cada pedido por segunda vez agrega un paso diario a un flujo que ya va apurado y no aprende nada: dentro de un año el problema sigue igual. Calcular el valor esperado desde el propio historial evita ambos inconvenientes, porque cada tienda se compara consigo misma y el criterio mejora conforme se acumulan semanas. Es además lo que el área ya hace a mano cuando compara un pedido contra el despacho anterior, así que automatizarlo no le pide a nadie cambiar de forma de pensar.

Dentro de ese enfoque, el árbol de decisión [3, 14] se eligió por una razón práctica antes

que estadística. Para reclamarle a un cliente hace falta poder decirle por qué: según sus últimas cuatro semanas esperábamos 117 unidades, usted pidió 432, y además hay una línea duplicada. Un modelo que solo entrega un puntaje no permite dar esa explicación.

La variable que no se mueve es la **precisión de las alertas**. Un sistema que marca de más se deja de mirar, que es el fracaso ya documentado en la Figura 4. Lo primero que cede es la **cobertura**: se prefiere dejar pasar algunos errores pequeños antes que inundar de avisos al analista. También cede el **alcance de la integración**, porque el software trabaja sobre el archivo exportado y no toca el ERP del cliente.

2.2. Por qué el proyecto se limita a estos datos

El trabajo se restringe al pan de hamburguesa que Bimbo despacha a las tiendas Bembos operadas por NGR y EyH: tres productos, 61 tiendas y 11 semanas de historial. No se abordan otros proveedores, categorías ni cadenas.

Esta restricción se tomó por las siguientes razones. Las tres presentaciones comparten unidad de medida, ciclo de reposición y comportamiento estacional, de modo que el valor esperado de una tienda es comparable con el de otra y el factor común semanal tiene sentido. Al ampliar a categorías con rotación distinta ese supuesto se rompe y habría que estimar un modelo por familia con menos datos cada uno. Trabajar sobre un universo cerrado permite además verificar contra hechos conocidos: el caso de la tienda de ATE está documentado por correo y sirve de comprobación de que el método detecta lo que debe, contraste que no existiría en un conjunto disperso de proveedores. La generalización a otras categorías queda como continuación natural, una vez validado el método en este universo.

2.3. Cómo funciona

El sistema corre sobre el archivo de pedidos antes del despacho y tiene dos partes. La primera calcula, con el historial hasta la semana anterior, cuánto debería pedir cada tienda de cada producto. La segunda compara ese número con el pedido real y decide si la diferencia es normal, usando un árbol de decisión [3, 14] sobre el residuo $e_t = (q_t - \hat{q}_t) / \max(\hat{q}_t, 1)$ y las variables de la Tabla 10.

Para el valor esperado $\hat{q}_t$ se probarán tres opciones, de la más simple a la más elaborada: el pedido de la semana anterior, $\hat{q}_t = q_{t-1}$, que es lo que hace hoy la analista y por eso es la referencia obligada; la mediana de las cuatro semanas previas, que aguanta que el propio historial tenga pedidos equivocados, cosa que el promedio no hace; y suavizamiento exponencial con ajuste por día de la semana [7], si el histórico da para tanto. Hay un detalle que puede arruinar el cálculo si se pasa por alto: el historial contiene los errores que se quieren detectar, así que la referencia sale inflada. Por eso se usan estimadores robustos y se recalcula excluyendo lo que la primera pasada marcó.

2.4. Con qué variables decide el árbol

Las variables c_{sku} y a_t salen del hallazgo de la Sección 1.7.5 y son las que un umbral simple no puede usar. Todas se calculan solo con la información registrada hasta el momento de evaluar cada línea; ninguna usa datos de semanas posteriores (Tabla 29).

Tabla 10: Variables del clasificador.

Variable	Qué mide
e_t	Diferencia relativa entre lo pedido y lo esperado.
z_{rob}	Cuántas desviaciones robustas se aleja el pedido de la mediana de su serie.
Δ_{prev}	Variación contra el pedido de la semana anterior.
d_{dup}	Si existe otra línea con la misma tienda, producto y cantidad en la misma fecha.
ρ_{mix}	Peso del producto dentro del pedido total de la tienda, comparado con su peso histórico.
c_{sku}	Si las tres presentaciones se movieron juntas. Cuando suben todas a la vez suele ser demanda real.
a_t	Mediana del residuo de todas las series esa semana. Separa el feriado del error de una tienda sola.
dow	Día de la semana de entrega.

2.5. De dónde sale la etiqueta

El extracto no trae un campo que diga «este pedido estuvo mal», así que hay que construirlo en dos pasos. Primero se marcan como candidatos los casos que el área ya reconoce: duplicidad exacta, residuo por encima del umbral acordado, diferencia entre lo pedido y lo consumido. Después se revisan uno por uno y se marcan como error o como normales.

Un caso solo se considera *error confirmado* cuando lo respalda evidencia operativa: un correo de alerta en que el área o la tienda reconoce el error, una corrección del pedido acompañada de su motivo o la confirmación expresa de la analista. Las líneas anuladas y reemplazadas por otra cantidad no se cuentan como errores de forma automática, porque la modificación puede deberse a un cambio legítimo de necesidad (Sección 10.5).

2.6. Contra qué se compara

El árbol se mide contra tres referencias. Un umbral sobre el pedido anterior, que reproduce el control manual actual y es el piso obligado; un umbral sobre z_{rob} , como regla estadística simple; y un Isolation Forest [10], que no necesita etiquetas y sirve para verificar si el criterio de etiquetado tiene sentido. El árbol se implementa en `scikit-learn` con profundidad limitada [12], y se usa gradient boosting [5] solo como techo de referencia, para saber cuánta exactitud cuesta la interpretabilidad; si se usa, se acompaña de valores de Shapley [11].

Si el árbol no le gana a los umbrales, hay que decirlo: que el problema se resuelva con una regla simple es un resultado válido, no un fracaso. El marco general de la tarea y sus métricas sigue a Chandola et al. [4], Hodge y Austin [6] y Aggarwal [1]; el proceso de trabajo sigue las fases de CRISP-DM [15] dentro del marco del PMBOK [13] y la adaptación de la forma de trabajo de Ambler y Lines [2].

2.7. El pedido que no llegó

Un pedido con cantidad equivocada se ve en el archivo; uno que nunca se emitió, no. Para el proveedor la segunda situación puede costar más: la tienda se queda sin producto, la venta no ocurre y nadie se entera hasta que alguien reclama.

El mismo cálculo que estima cuánto debería pedir una tienda detecta esos casos. Si una serie tienda–producto tiene valor esperado positivo para la semana en curso y en el archivo no aparece ninguna línea, la ausencia se reporta igual que una desviación de cantidad.

Las 180 series de tienda y producto por 11 semanas dan 1 980 combinaciones posibles, de las

cuales 1 913 tienen pedido. Faltan 67, y **21 son huecos intermedios**: semanas sin pedido entre semanas con pedido, repartidos en 7 series de tres tiendas. No están dispersos en el tiempo, sino concentrados entre el 20 de julio y el 10 de agosto, y las tres tiendas dejan de pedir y vuelven en fechas próximas.

Ese patrón importa para el diseño. Una ausencia no es por sí sola un error: puede ser una pausa con motivo, y varias tiendas que se detienen a la vez en la misma ventana apuntan a una causa compartida antes que a olvidos independientes. Distinguir una cosa de la otra exige el mismo contexto histórico que el resto del método y no un criterio aparte.

El software reporta las ausencias en una hoja separada del archivo de salida, con la tienda, el producto, la cantidad esperada y cuántas semanas lleva sin pedir, y deja la interpretación a quien conoce la operación.

2.8. El software

El entregable final es un software de validación de pedidos que funciona de la forma más simple posible: **entra un Excel y sale un Excel**. Quien revisa los pedidos carga el mismo archivo que hoy exporta del sistema de compras, sin transformaciones previas, y el programa devuelve otro con los productos cuyo pedido no coincide con lo que su historial permitía esperar. Lo que hoy significa recorrer miles de líneas a la vista pasa a ser revisar las pocas que quedan marcadas.

Entre esos dos extremos hay cuatro pantallas.

2.8.1. Cargar el archivo

El usuario arrastra el Excel y el programa revisa que sirva antes de procesarlo: que estén las columnas necesarias, que las fechas sean fechas y las cantidades números, y que el archivo corresponda al proveedor esperado. Si algo falta, lo dice con nombre propio, «no encuentro la columna Fe.Entrega», en lugar de fallar sin explicación. También avisa cuántas líneas anuladas encontró y cuántas va a analizar, para que el usuario sepa sobre qué está trabajando.

2.8.2. Revisar las alertas

La pantalla principal es una tabla con una fila por producto marcado, ordenada por valor en riesgo, con las columnas de la Tabla 11 y filtros por tienda, producto y nivel de alerta.

Tabla 11: Columnas del resultado.

Columna	Contenido
Tienda	Nombre y código de la tienda.
Material y descripción	Código y texto breve del producto.
Fecha de entrega	Fecha comprometida de la línea.
Cantidad pedida / esperada	Lo solicitado y lo que el historial anticipaba.
Desviación	Diferencia porcentual entre ambas.
Motivo	Cantidad fuera de rango, duplicidad, o ambas.
Nivel	Alta, media o baja, según cuánto supere el umbral.
Valor en riesgo	Exceso en unidades por el precio unitario.
Últimas semanas	Pedidos previos de esa tienda y producto.

Al hacer clic en una fila se abre una *ficha de detalle* con lo que el analista necesita para

decidir sin salir del programa: el gráfico de las últimas semanas de esa tienda y producto con el pedido actual resaltado, las otras dos presentaciones de la misma tienda esa semana, porque si subieron las tres es más probable que sea demanda real, y la regla exacta que disparó la alerta escrita en palabras.

Desde la misma ficha el analista marca la alerta como *confirmada* o *descartada*, y en el segundo caso escribe por qué. Ese registro de decisiones tiene un efecto que va más allá del orden: cada semana de uso genera ejemplos etiquetados sin trabajo adicional, de modo que el modelo puede reentrenarse con casos reales en lugar de depender de una única muestra revisada al inicio. Así, el uso de la herramienta genera los datos necesarios para mejorarla.

2.8.3. Ver lo que no llegó

Una segunda pestaña muestra las ausencias de pedido descritas en la Sección 2.7: tiendas y productos que debían pedir esa semana y no aparecen en el archivo, con la cantidad esperada y cuántas semanas llevan sin pedir. En la cabecera aparece además el aviso de campaña cuando el movimiento común de la semana supera el umbral κ , para que nadie interprete como error un alza que afectó a toda la cadena.

2.8.4. Exportar

El botón de descarga genera el Excel de salida con las alertas, las ausencias y las decisiones tomadas. Es el archivo que se adjunta al correo del cliente, y reemplaza el que hoy se arma a mano.

Una pantalla de configuración permite ajustar el umbral de alerta y la ventana de historial sin tocar el código, porque esos valores se calibran con el uso y no deberían requerir a un programador cada vez.

2.8.5. Cómo está construido

Se construye en Python con **pandas** y **scikit-learn** [12], y la interfaz se arma con Streamlit, que convierte un script de análisis en una aplicación con carga de archivos, tablas, filtros y gráficos sin escribir código de frontend. Corre en el equipo del usuario. Internamente encadena cinco pasos: lee y valida el archivo; calcula para cada tienda y producto la referencia con las k semanas previas; evalúa cada línea con lo registrado hasta su fecha de registro (acumulado de la semana y tamaño de la línea, Sección 10.1.3); separa el movimiento común de la cadena del propio de cada tienda; y aplica el modelo elegido, devolviendo la marca junto con la regla que la produjo. El modelo entrenado se guarda en disco, así que no reentrena en cada ejecución y responde en segundos. No requiere servidor, base de datos ni conexión con el ERP: trabaja sobre el archivo, igual que hoy trabaja la analista.

2.9. Objetivo

General. Construir y validar un sistema que estime el pedido esperado por tienda y producto a partir del historial, y que clasifique con un árbol de decisión las desviaciones frente al pedido real, usando solo la información disponible antes del despacho, y que alcance, en un periodo de prueba independiente, una precisión de al menos 70 % y una exhaustividad de al menos 80 % sobre errores confirmados con evidencia operativa, con entre 2 y 5 alertas por semana y al menos 3 días de anticipación respecto de la entrega, dentro de las 12 semanas del proyecto.

Tabla 12: El objetivo, letra por letra.

S	Detectar pedidos anómalos por tienda y producto antes del despacho, con la regla que justifica cada alerta.
M	Precisión $\geq 70\%$ y exhaustividad $\geq 80\%$ sobre errores confirmados; entre 2 y 5 alertas por semana; anticipación mediana de al menos 3 días (Tabla 26).
A	Los datos existen (11 semanas, 61 tiendas), las herramientas son de uso libre y el volumen corre en un equipo estándar.
R	Atiende un valor potencial en riesgo de alrededor de S/ 3 200 al mes y una tarea manual que hoy no escala.
T	Semana 12 del proyecto, evaluando una sola vez sobre un extracto posterior al 11 de septiembre que no se usa para construir el método.

2.10. Objetivos específicos

Cada objetivo específico tiene un indicador y una fecha que permiten verificar su cumplimiento.

Tabla 13: Objetivos específicos con su indicador de cumplimiento.

#	Objetivo específico	Indicador y meta	Semana
1	Limpiar y consolidar el extracto en una tabla tienda-producto-semana	El programa reproduce las cifras de la Sección 1.7 y excluye el 100 % de las líneas anuladas	2
2	Calcular el valor esperado de cada línea con la información disponible al registrarla	Error medio de la referencia menor que el de usar la semana anterior	7
3	Reunir casos de error confirmados con evidencia operativa	Al menos 20 errores confirmados, cada uno con su fuente	7
4	Entrenar el árbol y las reglas sencillas y elegir el método con el periodo de validación	Decisión documentada en el hito H3	8
5	Construir el software que recibe el Excel y devuelve las líneas a revisar con su motivo	Resultado en menos de 60 segundos y cumplimiento de los 9 criterios de la Tabla 17	11
6	Evaluar el método una sola vez en el periodo independiente	Precisión, exhaustividad, alertas por semana y anticipación reportadas frente a sus metas	12

3. Alcance y verificación

3.1. Qué entra y qué no

La corrección automática del pedido queda fuera de manera deliberada: decidir por la tienda cuánto debe pedir excede la responsabilidad que el proyecto puede asumir en esta etapa.

Tabla 14: Frontera del proyecto.

Dentro	Fuera
Limpieza y consolidación del extracto	Pronóstico de demanda para planificar producción
Cálculo del pedido esperado por tienda y producto	Integración dentro del ERP del cliente
Variables de desviación y contexto	Optimización de rutas, inventario o producción
Marcado de los casos que fueron error	Corrección automática del pedido
Árbol de decisión y líneas base, con validación temporal	Otros proveedores, otras categorías y otras cadenas (Sección 2.2)
Software que recibe el Excel y devuelve los productos anómalos	Despliegue en producción y soporte posterior

Tabla 15: Lo que se planifica, lo que se valida y lo que se investiga.

Restricción	Supuesto	Incertidumbre
El extracto cubre 11 semanas y no se puede alargar hacia atrás	Que las cantidades son comparables entre líneas del mismo producto	Cuánta de la desviación de una semana de campaña es demanda y cuánta error
No se puede modificar el ERP del cliente	Que el historial de correos alcanza para marcar suficientes casos	Cuántos de los 23 pedidos modificados son errores y cuántos cambios de necesidad
El proyecto cierra en la semana 12	Que el extracto refleja operación normal y no un período atípico	Con qué frecuencia aparecen errores por debajo del umbral, que hoy no se detectan
Los datos deben anonimizarse para uso académico	Que las alertas se responden dentro de los 30 minutos pactados	Si el patrón se sostiene al ampliar el historial más allá de 11 semanas

3.2. Restricciones, supuestos e incertidumbres

El riesgo de mayor impacto es que el sistema marque como error un pedido correcto y, por esa alerta, se recorte una cantidad que la tienda sí necesitaba. Ahí el proyecto deja de ahorrar y empieza a costar, porque un quiebre de stock vale más que el exceso que se buscaba evitar: la venta no ocurre y el reclamo pasa a ser del cliente hacia el proveedor. Los correos revisados muestran que la operación ya conoce ese riesgo y decide en su favor: ante la duda se despacha igual, para no desabastecer.

De ahí salen dos decisiones de diseño que aparecen en todo el documento. El sistema alerta pero no bloquea, de modo que ninguna alerta puede reducir un pedido por sí sola. Y la precisión se prioriza sobre la cobertura, aceptando que se escapen errores pequeños antes que marcar pedidos legítimos.

3.3. Qué se va a medir

Tabla 16: Evidencia mínima del proyecto.

Qué mido	Hoy	Con la solución	Cuándo
Pedidos erróneos detectados antes del despacho	Solo los que alguien nota al revisar el archivo	≥ 80 % de los confirmados	Semana 12
Precisión de las alertas	Sin medir	≥ 70 %	Semana 12
Alertas emitidas por semana	1 documentada en el extracto	entre 2 y 5	Semana 8
Unidades despachadas de más y detectadas	0	≥ 80 % de las 11 200 unidades de desviación identificadas en el extracto	Semana 12
Tiempo entre la carga del archivo y el resultado	Revisión manual de todo el archivo	Menos de un minuto	Semana 10

3.4. Criterios de aceptación del prototipo

Cada criterio está redactado de modo que la respuesta sea verdadero o falso, sin lugar a interpretación, e indica quién lo verifica y con qué evidencia queda demostrado.

Tabla 17: Criterios de aceptación del software.

#	Criterio	Quién verifica	Evidencia
1	Dado el archivo exportado del sistema de compras sin modificar, cuando se ejecuta la validación, entonces el software termina sin error y devuelve un Excel con las nueve columnas de la Tabla 11 completas en todas las filas.	Practicante	Archivo de salida de una semana real
2	Dado el caso documentado de la tienda de ATE en la semana del 17 de agosto, cuando se ejecuta la validación sobre ese período, entonces esa línea aparece marcada con nivel alto.	Practicante	Salida del software y correo de alerta original

#	Criterio	Quién verifica	Evidencia
3	Dadas dos líneas vigentes con la misma tienda, producto, fecha de entrega y cantidad, cuando se ejecuta la validación, entonces ambas quedan marcadas con motivo duplicidad.	Practicante	Salida sobre los 54 casos identificados en el extracto
4	Dada una serie tienda-producto con menos de k semanas de historial, cuando se evalúa su pedido, entonces aparece en la hoja de no evaluables y no en la de anomalías.	Practicante	Salida del software
5	Dada una semana cuyo factor común supera κ , cuando se ejecuta la validación, entonces el reporte incluye la advertencia de posible campaña.	Practicante	Salida sobre la semana del 27 de julio
6	Dada una tienda con valor esperado positivo y sin ninguna línea en el archivo, cuando se ejecuta la validación, entonces aparece en la hoja de ausencias con las semanas que lleva sin pedir.	Practicante	Salida sobre las 7 series con huecos intermedios
7	Dado el mismo archivo de entrada, cuando se ejecuta la validación dos veces, entonces ambos resultados son idénticos.	Practicante	Comparación de los dos archivos de salida
8	Dado un archivo al que le falta una columna obligatoria, cuando se ejecuta la validación, entonces el software nombra la columna faltante y no procesa.	Practicante	Captura del mensaje de error
9	Dado el archivo de una semana, cuando lo ejecuta alguien ajeno al proyecto sin acompañamiento, entonces obtiene el resultado en menos de un minuto y sin consultar el manual.	Practicante	Acta de la prueba de uso

El criterio 9 busca asegurar que el software pueda ser usado por el área sin depender de quien lo programó.

3.5. Viabilidad

Técnica. El volumen es pequeño y los modelos son ligeros. Python, `pandas` y `scikit-learn` bastan en un equipo corriente [12]. El proyecto está dimensionado para el perfil de quien lo ejecuta, una ingeniera industrial con manejo de análisis de datos: no requiere desarrollo web, base de datos ni despliegue en servidores. La interfaz se arma con Streamlit, que convierte un script de análisis en una aplicación con carga de archivos, tablas y gráficos sin escribir código de frontend, y las reglas legibles del árbol se obtienen directamente de `export_text` en `scikit-learn`. La parte propiamente informática del trabajo se reduce así a encadenar herramientas existentes.

Operativa. El área ya hace esta verificación a mano y aplica el mismo criterio de comparar contra el período anterior, así que el sistema no le pide cambiar de forma de pensar. Dos a cinco alertas semanales caben en la rutina que ya existe y en la ventana de 30 minutos ya pactada.

Económica. No hay licencias ni infraestructura que comprar. El costo es, principalmente, el tiempo de las personas que participan, estimado en S/ 5 256 con reservas (Sección 6). El valor potencial en riesgo, del orden de S/ 3 200 al mes, es comparable a ese costo, aunque no constituye un ahorro comprobado.

3.6. Plan de trabajo

El proyecto lo ejecuta una sola persona de principio a fin. No hay un equipo ni un área que valide entregas intermedias: el resultado se presenta a la jefatura al cierre y a la universidad como entregable académico. El plan está armado en consecuencia, sin pasos que dependan de que responda un tercero.

Las dos primeras semanas ya están hechas. El análisis exploratorio de la Sección 1.7 cubre la limpieza del extracto, el cálculo del valor esperado, la separación del residuo, la detección de duplicados y de ausencias y la estimación del exceso, y funciona sobre los datos reales. Lo pendiente empieza en la semana 3.

Sobre el orden de los pasos se tomaron dos decisiones. Las reglas simples se miden antes de entrenar el árbol, no después, para que la comparación no se acomode al resultado: el número contra el que hay que ganar ya está escrito cuando el árbol se entrena. Y el paso 3 va antes que el 4 porque sin casos marcados no hay con qué medir ninguno de los dos.

El paso 10 merece una nota, porque es el que hace que la herramienta mejore con el uso. Cada vez que alguien confirma o descarta una alerta desde la ficha queda un ejemplo marcado, sin trabajo adicional. A las pocas semanas de operación hay más casos revisados que los del paso 3, y el modelo puede reentrenarse con ellos. El etiquetado deja de ser un esfuerzo puntual del inicio y pasa a ser un subproducto del uso.

El hito del paso 5 es el que puede cambiar el rumbo. Si el árbol no le gana a las reglas simples, se deja el árbol y el software se construye igual sobre la regla que haya ganado: cambia cómo se decide qué marcar, no el resto de la herramienta. Que el problema se resuelva con una regla sencilla es un resultado válido y así se reportaría.

Tabla 18: Pasos del proyecto, su producto, la semana en que cierran y la herramienta con que se hacen.

#	Paso	Qué queda al terminarlo	Sem.	Con qué
<i>Hecho</i>				
1	Limpiar el dataset y explorarlo. Quitar las líneas anuladas, revisar formatos, armar las series semanales y medir el problema	Archivo limpio, el programa que lo limpia y las cifras de la Sección 1.7	1–2	pandas
<i>Modelo</i>				
2	Armar la tabla de señales. Para cada pedido, calcular las ocho señales que después mirará el modelo	Tabla con una fila por pedido y sus ocho señales	3–4	pandas
3	Marcar los casos que fueron error. Revisar los candidatos uno por uno apoyándose en el historial de correos de alerta y exigiendo evidencia operativa para cada error	Lista de casos marcados como error o como normales	4–7	Excel
4	Probar primero las reglas simples. Medir tres métodos sencillos para saber contra qué hay que ganarle	Resultado de las tres reglas	5–6	pandas, sklearn
5	Entrenar el árbol y compararlo con las reglas del paso 4	Comparación semana por semana. Hito: se decide si el árbol se justifica	7–8	sklearn

#	Paso	Qué queda al terminarlo	Sem.	Con qué
6	Decidir a partir de cuánto se avisa , buscando el punto donde el número de alertas por semana sigue siendo revisable	Umbral fijado y curva umbral-alertas	8	<code>pandas</code>
7	Escribir el motivo en palabras. Convertir lo que decide el modelo en una frase que el cliente entienda	Texto del motivo para cada alerta	8	<code>export_text</code>
<i>Software</i>				
8	Motor de cálculo. Una función que recibe la ruta del Excel y devuelve la tabla de alertas	Programa que ya funciona, aunque sin pantallas	9	<code>pandas</code>
9	Pantalla de carga y tabla de alertas. Arrastrar el archivo, avisar qué falta si algo no está, y mostrar el resultado con filtros por tienda, producto y nivel	Aplicación usable de punta a punta	10	Streamlit
10	Ficha de detalle y registro de decisiones. Gráfico de las últimas semanas, las otras dos presentaciones, la regla que disparó la alerta, y botones para confirmar o descartar	Ficha por alerta e historial de decisiones	11	Streamlit
11	Ausencias, aviso de campaña y descarga del Excel de salida	Archivo de salida completo	11	Streamlit
<i>Cierre</i>				
12	Probarlo sobre una semana real, ajustar y documentar	Manual de uso, informe final y resultados	12	–

4. Propuesta de solución

4.1. Alternativas identificadas

Para responder al problema delimitado en la Sección 1 se consideraron cuatro alternativas, que atacan la causa raíz desde lugares distintos de la operación:

- A. Tope fijo en el ERP.** Establecer en el sistema de compras del cliente una cantidad máxima por producto y tienda, por encima de la cual el pedido no se acepta.
- B. Doble confirmación de la tienda.** Pedir a cada tienda que confirme su pedido antes del cierre, por ejemplo mediante un mensaje o un formulario.
- C. Automatizar la emisión del pedido.** Que un software calcule y envíe el pedido de cada tienda, eliminando la digitación manual. Es la alternativa sugerida por el asesor en la primera revisión.
- D. Validación con el historial de cada tienda.** Que el proveedor compare cada pedido recibido con lo que esa tienda suele pedir y alerte, con su motivo, cuando la diferencia no tenga explicación.

4.2. Criterios de selección

Las alternativas se compararon con cinco criterios, ponderados según su importancia para el proveedor. La precisión de las alertas recibe el mayor peso porque es la variable que el proyecto declaró innegociable (Sección 2.1): una alerta que no se cree deja de mirarse. Cada alternativa se calificó de 1 (desfavorable) a 5 (favorable); las letras corresponden a las alternativas de la sección anterior.

Tabla 19: Matriz de selección de alternativas.

Criterio	Peso	A	B	C	D
Distingue tiendas y semanas distintas	30 %	1	3	4	4
No requiere permisos ni cambios en el cliente	25 %	1	2	1	5
Explica el motivo de cada observación	20 %	3	2	2	5
Costo y plazo dentro de 12 semanas	15 %	3	4	1	4
Se replica con otros clientes	10 %	2	3	1	5
Puntaje ponderado		1,80	2,70	2,10	4,55

La alternativa D obtiene el mayor puntaje. La C es la única que elimina el error en su origen, pero exige permisos del cliente, se tendría que rehacer para cada cadena y trasladada al proveedor la responsabilidad del pedido (Sección 9). La A es la más sencilla, pero trata igual a una tienda de centro comercial que a una de barrio. La B no requiere tecnología, pero agrega un paso diario a un proceso que ya funciona con plazos ajustados.

4.3. Solución seleccionada y prototipo previo

La solución seleccionada es un **software de validación de pedidos** que recibe el Excel que el área ya exporta del sistema de compras y devuelve otro Excel con las líneas que se deben revisar, indicando cuánto se pidió, cuánto se esperaba y por qué se marcó. El software alerta pero no bloquea: la decisión final sigue siendo de la persona.

La solución cuenta ya con un **prototipo previo** funcional, construido en las semanas 1 a 6. No tiene todavía pantallas, pero ejecuta el recorrido completo de principio a fin: lee el archivo original, descarta las líneas anuladas, calcula para cada línea las señales que se conocen en el momento de su registro y produce un Excel con las alertas y su motivo (Figura 14). Este prototipo es el que permitió medir las reglas de la Sección 10.6 y la versión por pedido de la Sección 10.7. Lo que falta construir es el modelo de decisión definitivo y la interfaz de uso.

4.4. Estructura de desglose del trabajo

La Figura 8 descompone el proyecto en cinco entregables y diecinueve paquetes de trabajo. Cada paquete termina en un producto verificable.

4.5. Paquetes de trabajo

4.6. Entregables y criterios de aceptación

Cada entregable de primer nivel de la EDT tiene una condición verificable que indica cuándo está terminado y la evidencia que lo demuestra (Tabla 21). Los criterios detallados del software se encuentran en la Tabla 17.




Figura 8: Estructura de desglose del trabajo (EDT) del proyecto.

Tabla 20: Paquetes de trabajo, su producto y su esfuerzo estimado. La responsable de todos es la autora del proyecto.

Código	Paquete	Producto verificable	Horas	Estado
1.1–1.3	Diagnóstico	Archivo limpio, cifras del problema y programa que las reproduce	40	Hecho
2.1	Tabla de señales	Excel con las señales por línea y por semana	20	Hecho
2.2	Casos con evidencia	Lista de casos con su etiqueta y la evidencia que la respalda	24	En curso
2.3	Reglas sencillas	Métricas por periodo de tres reglas y de la versión por pedido	16	Hecho
2.4	Árbol y comparación	Árbol entrenado y comparación con la mejor regla	20	Pendiente
2.5	Umbral y motivos	Umbral elegido y frase explicativa por alerta	12	Pendiente
3.1	Motor de cálculo	Función que transforma el Excel en la tabla de alertas	16	Pendiente
3.2–3.4	Interfaz	Aplicación con carga, alertas, ficha, ausencias y descarga	40	Pendiente
4.1–4.3	Validación	Resultados en el periodo independiente y acta de prueba de uso	24	Pendiente
5.1–5.3	Gestión y cierre	Informes, manual de uso e informe final	28	En curso
Total			240	

Tabla 21: Entregables del proyecto y su criterio de aceptación.

Entregable	Se acepta cuando...	Evidencia	Semana
1 Diagnóstico	El programa reproduce desde el archivo original las cifras del problema	Salidas 01_limpio.xlsx y Sección 1.7	2
2 Modelo	Existe una decisión documentada entre árbol y regla, tomada con el periodo de validación y con al menos 20 errores confirmados	Registro de casos con evidencia y comparación por periodo	8
3 Software	Cumple los 9 criterios de aceptación de la Tabla 17	Archivo de salida y acta de prueba	11
4 Validación	Las métricas se calcularon una sola vez sobre el periodo independiente y se reportan frente a sus metas	Informe de resultados	12
5 Gestión y cierre	El asesor aprueba el informe final y la jefatura recibe el manual de uso	Acta de entrega	12

4.7. Resultados esperados

Al cierre de la semana 12 se espera contar con tres resultados. El primero es un **software** que, a partir del archivo exportado y en menos de un minuto, entregue las líneas a revisar con su motivo y con varios días de anticipación respecto de la entrega. El segundo es una **evaluación** del método sobre un periodo que no se usó para construirlo, expresada en la proporción de alertas que resultaron ser errores confirmados y en la proporción de errores que el método detectó. El tercero es un **registro de casos** revisados con evidencia, que permita seguir mejorando el método con el uso. Si la evaluación muestra que el árbol de decisión no supera a la mejor regla sencilla, el software se entregará igualmente sobre esa regla, y ese hallazgo se reportará como resultado.

5. Cronograma

5.1. Diagrama de Gantt preliminar

El proyecto se organiza en doce semanas. La Figura 9 muestra las tareas, su duración y su estado al cierre de la semana 6. El detalle de cada paso se encuentra en la Tabla 18.

El cronograma incorpora un ajuste respecto del plan original: la decisión sobre el árbol de decisión se traslada de la semana 7 a la 8, porque antes es necesario confirmar los casos con evidencia y recalcular las señales con la información disponible en cada momento. El desplazamiento se absorbe dentro de la semana 8 y no modifica la fecha de entrega. La secuencia que determina esa fecha es la confirmación de casos, el entrenamiento del árbol, la elección del umbral y la construcción del motor de cálculo; su eslabón más frágil es la confirmación de casos, porque depende de los correos que conserva el área de planeamiento.

5.2. Identificación de hitos

La Tabla 22 indica, para cada hito, la decisión que se toma y quién la toma.




Figura 9: Diagrama de Gantt preliminar. Las barras oscuras están completadas; la línea vertical marca el corte de este avance.

Tabla 22: Hitos del proyecto.

Hito	Semana	Decisión que se toma	Quién decide	Estado
H1 Diagnóstico	2	El problema está medido y justifica el proyecto	Asesor	Cumplido
H2 Línea base fijada	6	Se fija la cifra que el modelo debe superar	Autora	Cumplido
H3 ¿Árbol o regla?	8	Se decide si el árbol aporta frente a la mejor regla	Autora, con visto bueno del asesor	Pendiente
H4 Motor operativo	9	El cálculo funciona de punta a punta sin pantallas	Autora	Pendiente
H5 Aplicación completa	11	La herramienta está lista para la prueba de uso	Autora	Pendiente
H6 Entrega final	12	Se acepta el prototipo según los criterios de la Tabla 17	Asesor y jefatura	Pendiente

6. Presupuesto

6.1. Estimación preliminar de costos

El proyecto no requiere compras de equipos ni licencias: todas las herramientas son de uso libre y el volumen de datos se procesa en una computadora personal. Su costo es, principalmente, el tiempo de las personas que participan. La Tabla 23 lo valoriza para dar una idea del esfuerzo que representa. Ninguna partida implica un desembolso adicional para la empresa, salvo las horas que destinen la analista y la jefatura.

Tabla 23: Estimación preliminar de costos del proyecto (12 semanas).

Partida	Cantidad	Costo unitario (S/)	Total (S/)
<i>Personas</i>			
Practicante (autora)	240 h	12	2 880
Asesor académico	12 h	80	960
Analista de planeamiento (revisión de casos y prueba de uso)	8 h	25	200
Jefatura de planeamiento (hitos y cierre)	2 h	50	100
<i>Equipos y servicios</i>			
Computadora personal (uso prorrateado de 3 meses)	3 meses	83	250
Internet y energía	3 meses	60	180
Software (Python, pandas, scikit-learn, Streamlit, L ^A T _E X)	–	0	0
Línea base de costos			4 570
Reserva de contingencia (10 %)			457
Presupuesto del proyecto			5 027
Reserva de gestión (5 %, fuera de la línea base)			229
Total con reservas			5 256

La **reserva de contingencia** cubre riesgos ya identificados en la Sección 7, en particular que la confirmación de casos o la obtención del extracto independiente tomen más horas de las previstas; su uso lo autoriza la autora y se registra con su motivo. La **reserva de gestión** cubre imprevistos que no figuran en el registro de riesgos, como un cambio de alcance solicitado por la empresa; su uso requiere la aprobación del asesor.

Como referencia, el valor potencial en riesgo estimado en la Sección 1.7 es de alrededor de S/ 3 200 al mes. Esta cifra no es una pérdida comprobada (Sección 10.1.2), por lo que no se usa para calcular un retorno de la inversión; solo indica que el orden de magnitud del problema es comparable al costo total del proyecto.

6.2. Supuestos utilizados

- El esfuerzo de la practicante es de 20 horas por semana durante 12 semanas, valorizado en S/ 12 por hora, una cifra cercana a la subvención mensual de prácticas.
- El asesor dedica una hora por semana, valorizada a una tarifa referencial de docencia de S/ 80 por hora.

- La analista dedica 6 horas a confirmar casos y 2 a la prueba de uso; la jefatura, 2 horas a hitos y cierre. Ambas se valorizan con tarifas horarias referenciales, no con salarios reales.
- La computadora es propia, con un valor de S/ 3 000 y una vida útil de 36 meses; se imputa el uso de 3 meses.
- No se contratan servicios en la nube ni licencias: el software corre en el equipo del usuario.
- Las tarifas son supuestos de orden de magnitud y deberán validarse con el área si el presupuesto se usa para decidir.

7. Riesgos

7.1. Lista preliminar de riesgos

La Tabla 24 actualiza la matriz del primer entregable con lo observado en la ejecución y con la retroalimentación del asesor. Cada riesgo se describe como una condición y su consecuencia, con la señal que permite anticiparlo.

Tabla 24: Lista de riesgos con probabilidad (P) e impacto (I) de 1 a 5, y estrategia de respuesta.

ID	Si... entonces...	P	I	Estrategia	Respuesta y señal temprana
R1	Si no se reúnen 20 errores confirmados, el modelo no tendrá de qué aprender	5	4	Mitigar	Confirmar los 78 casos con correos en la semana 7. Señal: hoy hay un solo error confirmado
R2	Si el modelo usa información que no existe al alertar, su desempeño real será menor	4	4	Evitar	Calcular todas las señales con lo registrado hasta cada momento. Señal: la versión por pedido ya rinde menos que la semanal
R3	Si no se obtiene un extracto posterior, no habrá evaluación independiente	3	5	Mitigar	Solicitarlo en la semana 7; si no llega, reservar las dos últimas semanas del extracto actual sin usarlas
R4	Si el árbol se ajusta demasiado a pocas semanas, fallará con datos nuevos	3	4	Mitigar	Limitar su profundidad y compararlo solo en validación. Señal: gran diferencia entre ajuste y validación
R5	Si las campañas generan alertas correctas pero inútiles, el analista dejará de mirarlas	3	4	Mitigar	Usar el movimiento común de la cadena. Señal: más de 10 % de series en alza la misma semana
R6	Si el historial contiene errores, la referencia quedará inflada	3	3	Mitigar	Usar medianas y recalcular sin los casos confirmados
R7	Si el software no se adopta, se volverá a la revisión manual	2	4	Mitigar	Interfaz de un solo paso y criterio de aceptación 9
R8	Si cambia el formato del archivo exportado, el programa fallará	2	3	Aceptar	Verificar columnas al inicio con un mensaje explícito

7.2. Matriz de probabilidad e impacto

7.3. Estrategias de respuesta

Los riesgos R1, R2 y R3 son los que más pueden afectar el resultado del proyecto, ya que tienen que ver con cuántos errores se confirman, qué información se usa para alertar y en qué periodo se mide el desempeño. Por eso se atienden en la semana 7, antes de entrenar el árbol.




Figura 10: Matriz de probabilidad e impacto. Los riesgos en rojo requieren respuesta inmediata; los ámbar, seguimiento semanal.

Los riesgos R4 a R6 se mitigan con decisiones de diseño ya incorporadas al método. El R7 se gestiona con la prueba de uso de la semana 12 y el R8 se acepta, porque su impacto es acotado y su detección inmediata.

8. Indicadores

La Tabla 25 muestra cómo cada elemento del plan responde al anterior: el problema da lugar a la causa raíz, esta al objetivo, el objetivo a un entregable y el entregable a un indicador que permite verificarlo.

Tabla 25: Alineación entre problema, objetivos, entregables e indicadores.

Causa que se ataca	Objetivo específico	Entregable	Indicador
No hay un valor de referencia por tienda	2. Valor esperado con información disponible	2 Modelo	Error de la referencia
La revisión es visual y no prioriza	4. Elegir el método que alerta mejor	2 Modelo	Precisión y exhaustividad
Las alertas llegan tarde o no se revisan	5. Software con motivo y anticipación	3 Software	Carga de alertas y anticipación
No se sabe si el control funciona	3 y 6. Casos confirmados y evaluación independiente	4 Validación	Errores confirmados

La Tabla 26 define los indicadores con que se medirá el proyecto. Se distinguen los indicadores de *resultado*, que dicen si el problema se está resolviendo, de los indicadores *líderes*, que avisan con anticipación si el resultado está en riesgo.

9. Retroalimentación incorporada

El asesor planteó delimitar mejor el problema: que el pedido no lo envíe el usuario de tienda sino directamente un software. La idea ataca el error en su origen, porque si nadie digita no hay nada que digitar mal. Se evaluó y se optó por otra delimitación, porque las dos propuestas

Tabla 26: Indicadores clave del proyecto.

Indicador	Cómo se calcula	Meta	Tipo	Hoy
Precisión de las alertas	Alertas que resultan ser errores confirmados / alertas emitidas	$\geq 70 \%$	Resultado	Por medir
Exhaustividad	Errores confirmados detectados / errores confirmados	$\geq 80 \%$	Resultado	1 de 1
Carga de alertas	Alertas emitidas por semana	2 a 5	Resultado	2 a 6
Anticipación	Días entre la alerta y la fecha de entrega (mediana)	≥ 3 días	Resultado	3 a 5
Tiempo de proceso	Segundos entre la carga del archivo y el resultado	< 60 s	Resultado	17 s (prototipo)
Errores confirmados	Casos con evidencia operativa acumulados	≥ 20	Líder	1

automatizan cosas de naturaleza distinta y solo una corresponde al proveedor: el envío del pedido es un proceso de cara al cliente, la detección de errores es un control interno del proveedor.

Tabla 27: Automatizar el pedido frente a automatizar la detección.

	Automatizar el pedido	Automatizar la detección
Dónde corre	En el proceso de compras del cliente	En el proveedor, sobre su propio archivo
Permisos	Compras y TI del cliente	Ninguno
Al replicarlo con otro cliente	Hay que rehacerlo: otro ERP, otro formato, otro calendario	Funciona igual: el dato de entrada es del proveedor
Si se equivoca	El pedido errado lo emitió el proveedor	Se pierde una alerta; el pedido sigue siendo del cliente
Sobre la relación	Elimina el contacto semanal	Le da contenido

Automatizar el flujo con el cliente tiene tres costos. El primero es que el esfuerzo no se acumula: el pedido cambia de cliente a cliente y con la temporada, de modo que habría que construir y mantener una integración por cada cadena, sin reutilizar nada con la siguiente. El segundo es que ese pedido semanal es la línea directa con el cliente, el momento en que el proveedor se entera de lo que la tienda cree que va a necesitar; ahí aparecen las señales de que algo cambió, desde una caída sostenida hasta el reparto del volumen con otro proveedor. Un sistema que genera los pedidos por su cuenta deja de recibir esa señal y se enteraría tarde, cuando el volumen ya bajó. El tercero es un traslado de responsabilidad: hoy, si la cantidad está mal, el error es del cliente y el proveedor tiene con qué sustentarlo; si el proveedor emitiera los pedidos, cualquier sobre-despacho pasaría a ser error propio, con la discusión comercial y la devolución a cuenta suya.

El control interno no tiene ninguno de esos costos. Corre sobre datos que el proveedor ya tiene, sirve igual para cualquier cliente que emita pedidos, y no sustituye la conversación sino que le da contenido: en lugar de un correo que dice «su pedido parece alto», el área envía la cantidad solicitada, la esperada según el historial de esa tienda y el motivo. Esto aporta más a la relación con el cliente que emitir el pedido por él. En resumen, se automatiza el proceso que pertenece al proveedor y es estable, y se deja fuera el que es compartido con el cliente y cambia con cada cadena.

La observación sí amplió el alcance en un punto. Si el software estima la demanda esperada de cada tienda, también puede detectar la ausencia de pedido: una tienda que debía pedir y no pidió. Ese caso no estaba contemplado y se incorporó según la Sección 2.7.

9.1. Segunda revisión del asesor

La revisión del avance planteó seis observaciones. La Tabla 28 resume cómo se incorporó cada una y en qué sección se desarrolla. Estas observaciones modificaron tres aspectos del proyecto: qué información puede usar el método, qué se considera un error y sobre qué periodo se mide el desempeño.

Tabla 28: Observaciones de la segunda revisión y su incorporación.

Observación	Cambio realizado	Sección
Cada variable debe conocerse al emitir la alerta	Se clasificaron las variables por disponibilidad y se construyó una versión que evalúa cada línea con lo sabido ese día	10.1.1, 10.7
Distinguir desviación de error confirmado	Terminología de tres niveles: desviación, caso sospechoso y error confirmado	10.1.2
Distinguir valor en riesgo de pérdida ocurrida	Los S/ 3 200 mensuales se presentan como valor potencial en riesgo	10.1.2, 1.7
Validar etiquetas con evidencia operativa	Cada error exige una fuente documentada; las modificaciones de cantidad dejan de contarse como errores	10.5
Pasar del análisis semanal a alertas por pedido	Procedimiento en tres etapas, ya implementado en el prototipo	10.1.3
Reservar un periodo independiente y moderar conclusiones	Periodos de ajuste, validación y prueba; las cifras se reportan como preliminares	10.1.4

10. Avance del proyecto: semanas 3 a 6

Entre la tercera y la sexta semana se completaron los pasos 2, 3 y 4 del plan de trabajo (Tabla 18) y se revisaron las cifras del paso 1. En el mismo periodo se recibieron las observaciones del asesor sobre el primer entregable. Como varias de ellas cambian la forma de leer los resultados, se presentan primero.

Los resultados se obtuvieron con un programa en Python que lee el archivo exportado del sistema de compras sin modificarlo, por lo que pueden repetirse con cualquier exportación del mismo formato. Las capturas de los archivos de salida y del código están en el Anexo A. Como se trabajó con pocas semanas y con etiquetas aún no confirmadas, los resultados son preliminares.

10.1. Retroalimentación del asesor y cómo se incorpora

El asesor señaló seis aspectos, resumidos en la Tabla 28; los apartados siguientes los desarrollan.

10.1.1. Qué información existe en el momento de alertar

Si el objetivo es alertar antes del despacho, el método solo puede usar lo que se sabe en ese momento. En el archivo, cada línea se registra en promedio cinco días antes de su fecha de entrega, y el 80 % se registra con menos de una semana de anticipación. Esto significa que, cuando se registra una línea, todavía no se conocen las demás líneas que la misma tienda cargará esa semana, ni lo que pedirá la semana siguiente. La Tabla 29 clasifica las variables según este criterio.

Tabla 29: Disponibilidad de cada variable en el momento de emitir la alerta.

Variable	¿Disponible al alertar?	Tratamiento
Referencia de la tienda (semanas previas)	Sí	Se calcula solo con entregas ya realizadas
Variación frente a la semana anterior	Sí	Sin cambios
Línea duplicada	Sí, parcialmente	Se compara con las líneas ya registradas hasta ese momento
Peso del producto en el pedido de la tienda	Parcialmente	Se calcula con lo registrado hasta ese momento
Presentaciones que suben juntas	Parcialmente	Se calcula con lo registrado hasta ese momento
Movimiento común de la cadena	Parcialmente	Se calcula con las tiendas que ya registraron su pedido
Lo que la tienda pide la semana siguiente	No	Solo para análisis retrospectivo; queda fuera del modelo

Esto afecta a dos elementos del primer entregable. La última fila de la Tabla 5 usa el comportamiento de la semana siguiente; sirvió para diferenciar una campaña de un error, pero no puede usarse para alertar. Lo mismo ocurre con el parámetro de reversión de la Tabla 6, que queda solo para revisar casos pasados. Además, los resultados semanales de esta sección usan semanas completas y son, por ello, más favorables que lo que se obtendría en operación.

10.1.2. Desviación, caso sospechoso y error confirmado

En el primer entregable se usaron como sinónimos «desviación», «anomalía» y «error». A partir de este avance se usan tres términos distintos:

- *Desviación*: pedido que se aleja del patrón histórico de la tienda. No implica que esté mal; puede deberse a una promoción, a un evento local o a un cambio de necesidad.
- *Caso sospechoso*: desviación que, por sus características, se debe revisar.
- *Error confirmado*: caso sospechoso respaldado por evidencia operativa, por ejemplo un correo en que el área o la tienda reconoce el error.

Con esta distinción, los 17 casos y los S/ 3 200 mensuales de la Tabla 4 corresponden a desviaciones. Esa cifra es un valor potencial en riesgo, es decir, el valor del producto despachado por encima de lo esperado si todas las desviaciones fueran errores. La pérdida real será menor y se podrá estimar cuando se sepa cuántas desviaciones se confirman y qué parte del exceso no se recuperó por otra vía.

10.1.3. Del análisis semanal a la alerta por pedido

El análisis exploratorio agrupó los pedidos por tienda, producto y semana, pero la herramienta final debe evaluar cada línea cuando se registra. Para ello se combinan tres comparaciones:

1. La referencia de la tienda sigue siendo semanal y se calcula con las semanas anteriores, que ya se conocen.

2. Al registrarse una línea, se suma con las líneas de la misma tienda y producto ya cargadas para esa semana, y el acumulado se compara con lo que la tienda suele llevar pedido hasta ese día.
3. La línea se compara también con el tamaño habitual de las líneas de esa tienda y producto, para detectar errores que en el total semanal no se notan (Sección 10.5).

Así, la alerta corresponde a una línea concreta y puede emitirse el mismo día del registro, varios días antes de la entrega.

10.1.4. Periodos de ajuste, validación y prueba

Hasta ahora el extracto se dividía en dos partes: hasta el 10 de agosto para ajustar y las tres semanas siguientes para evaluar. Sin embargo, esas tres semanas también se revisaron al definir los casos sospechosos y al estudiar el caso de ATE, así que no son independientes. Se adopta entonces esta división:

- Ajuste (6 de julio al 10 de agosto): para construir el método.
- Validación (17 al 31 de agosto): para comparar alternativas y elegir umbrales.
- Prueba (extracto posterior al 11 de septiembre): se pedirá al área de planeamiento y solo se usará al final. El desempeño del método se reportará con este periodo.

Por eso, las cifras de la Sección 10.6 se presentan como resultados de validación.

10.2. Resumen del estado del proyecto

Los productos comprometidos hasta la semana 6 están terminados. Lo que todavía no se puede afirmar es si las alertas alcanzarán la precisión buscada, porque falta confirmar los casos de error. La Tabla 30 resume la situación.

Tabla 30: Estado del proyecto al cierre de la semana 6. Las cifras de desempeño son de validación y se calcularon con etiquetas aún no confirmadas.

Aspecto evaluado	Meta	Situación actual	Estado
Productos de los pasos 1 a 4	4 de 4	4 de 4	Cumplido
Alertas que coinciden con un caso sospechoso	70 % o más	45 % (preliminar)	Lejos
Casos sospechosos que el método detecta	80 % o más	71 % (preliminar)	Cerca
Alertas por semana	Entre 2 y 5	3,7	Cumplido
Errores confirmados con evidencia operativa	20 o más	1 (caso ATE)	Lejos

Por ahora solo hay un error confirmado por escrito (ATE); los demás son casos sospechosos. Hasta que esa cifra aumente, las medidas de desempeño deben tomarse como provisionales.

10.3. Revisión de la limpieza de datos

El programa de limpieza reprodujo casi todas las cifras de la Sección 1.7.1: 10374 líneas vigentes, 385 anuladas con reemplazo y 119 líneas duplicadas. Cambiaron dos valores.

Las líneas anuladas que se reemplazaron por otra cantidad pasan de 27 a 23. Cuando una tienda tiene varias líneas del mismo producto el mismo día, no es evidente cuál reemplazó a cuál; el programa toma la primera según el número de orden y posición.

Las observaciones evaluables bajan de 1 554 a 1 371 porque se excluyó la última semana. El archivo termina un viernes y esa semana no tiene los pedidos del sábado, por lo que aparentaba una caída general.




Figura 11: Unidades pedidas por semana, considerando solo líneas vigentes. La última barra corresponde a una semana incompleta.

10.4. Paso 2: la tabla de señales

Para cada tienda, producto y semana se calcularon las ocho señales de la Tabla 10. Estas indican cuánto se aleja el pedido de lo que la tienda suele pedir, cuánto cambió frente a la semana anterior, si hay una línea repetida, si subieron las tres presentaciones y si toda la cadena se movió en la misma dirección. Esta versión usa semanas completas; la versión por pedido se describe en la Sección 10.7.

Tienda	Material	semana	dow	q	q_ref	q_prev	e_t	z_rob	d_prev	d_dup	rho_mix	c_sku	a_t	u_t	evaluable
BB FC LA FONTANA	201985	29/06/2026	2	900								0			FALSO
BB FC LA FONTANA	201985	06/07/2026	0	1206		900			0.34	0	-0.01	0			FALSO
BB FC LA FONTANA	201985	13/07/2026	0	1062	1053	1206	0.01	0.04	-0.12	0	0.00	0	0.14	-0.13	VERDADERO
BB FC LA FONTANA	201985	20/07/2026	0	1044	1062	1062	-0.02	-0.08	-0.02	0	0.01	0	0.02	-0.04	VERDADERO
BB FC LA FONTANA	201985	27/07/2026	0	864	1053	1044	-0.18	-1.57	-0.17	0	-0.04	0	0.11	-0.29	VERDADERO
BB FC LA FONTANA	201985	03/08/2026	0	1206	1053	864	0.15	1.27	0.40	0	0.02	0	0.04	0.11	VERDADERO
BB FC LA FONTANA	201985	10/08/2026	0	1116	1053	1206	0.06	0.52	-0.07	0	0.01	0	0.05	0.01	VERDADERO
BB FC LA FONTANA	201985	17/08/2026	0	1098	1080	1116	0.02	0.15	-0.02	0	0.01	0	-0.11	0.12	VERDADERO
BB FC LA FONTANA	201985	24/08/2026	0	1224	1107	1098	0.11	1.46	0.11	0	0.01	0	-0.03	0.14	VERDADERO
BB FC LA FONTANA	201985	31/08/2026	0	1080	1161	1224	-0.07	-1.01	-0.12	0	-0.01	0	-0.05	-0.02	VERDADERO
BB FC LA FONTANA	201985	07/09/2026	1	774	1107	1080	-0.30	-6.02	-0.28	0	0.01	0	-0.32	0.02	FALSO
BB FC LA FONTANA	201986	29/06/2026	2	1890						0		0			FALSO
BB FC LA FONTANA	201986	06/07/2026	0	2490		1890			0.32	0	-0.02	0			FALSO
BB FC LA FONTANA	201986	13/07/2026	0	2250	2190	2490	0.03	0.13	-0.10	0	0.01	0	0.14	-0.12	VERDADERO
BB FC LA FONTANA	201986	20/07/2026	0	2190	2250	2250	-0.03	-0.17	-0.03	0	0.01	0	0.02	-0.05	VERDADERO

Figura 12: Captura de salidas/02_senales.xlsx abierto en Excel: una fila por tienda, producto y semana con sus señales. El código que la genera se muestra en la Figura 22.

La tabla tiene 1 371 filas evaluables. La semana del 27 de julio vuelve a mostrar un alza de toda la cadena, que coincide con Fiestas Patrias. La semana del 13 de julio muestra el mismo comportamiento sin un motivo conocido, y se consultará al área de planeamiento. El pedido de ATE del 17 de agosto vuelve a aparecer marcado (Figura 13).




Figura 13: Tienda de ATE, pan grande. El pedido de la semana del 17 de agosto se aleja de la referencia y coincide con el caso reportado por correo.

10.5. Paso 3: casos sospechosos y su validación

El archivo no indica qué pedidos estuvieron mal, así que la lista de errores se construye en dos pasos: el programa selecciona pedidos sospechosos y propone una etiqueta, y luego cada propuesta se confirma o descarta con evidencia operativa.

Se seleccionaron 78 pedidos por cuatro motivos: alza solo en esa tienda, línea duplicada, ambas cosas o caída brusca. Se propone como posible error cuando la tienda subió sola, sin que subieran las demás tiendas ni sus otras presentaciones, o cuando hay una línea duplicada con un alza importante (Tabla 31).

Tabla 31: Pedidos sospechosos según el motivo y la etiqueta propuesta.

Motivo	Possible error	Probablemente normal
Alza que solo afectó a la tienda	8	8
Línea duplicada	4	38
Línea duplicada con alza	1	0
Caída brusca	0	19
Total	13	65

Tienda	Motivo	semana	q	q_ref	e_t	u_t	a_t	c_sku	d_dup	rectificada	motivo_candidato	etiqueta_propuesta	confianza	fuentes	etiqueta_final	comentario_revision
BB TDA JOCKEY PLAZA	201985	27/07/2026	4572	594	3.16	3.05	0.11	3	0	0	alza propia u_t>t	normal	alta	regla de candidato	normal	
BB TDA PATE	201985	17/08/2026	4332	117	2.62	2.80	-0.13	3	1	0	alza propia u_t>t	error	alta	regla de candidato	error	
BB TDA STRIP LA MAR IN LINE	201985	10/08/2026	3410	1320	1.66	1.54	0.11	3	1	0	duplicidad a_t>t	normal	media	regla de candidato	error	
BB TDA PLAZA LIMA SUR FC	201985	10/08/2026	979.34	405	1.42	1.37	0.05	2	0	0	alza propia u_t>t	normal	media	regla de candidato	error	
BB TDA PV ATE	201985	24/08/2026	252	117	1.15	1.19	-0.03	3	0	0	alza propia u_t>t	normal	baja	regla de candidato	normal	
BB TDA PV ATE	201986	31/08/2026	660	315	1.10	1.15	-0.05	2	0	0	alza propia u_t>t	normal	media	regla de candidato	error	
BB TDA PV ATE	201986	24/08/2026	630	300	1.10	1.13	-0.03	3	0	0	alza propia u_t>t	normal	baja	regla de candidato	normal	
BB TDA PLAZA CENTER VENT EXPRS	201985	17/08/2026	108	54	1.11	1.11	-0.01	2	0	0	alza propia u_t>t	normal	media	regla de candidato	error	
BB K UTP LIMA CENTRO	201987	31/08/2026	180	240	1	1.05	0.05	2	0	0	alza propia u_t>t	normal	media	regla de candidato	error	
BB TDA PLAZA LIMA NORTE FOOD C	201985	27/07/2026	702	333	1.11	0.99	0.11	3	0	0	alza propia u_t>t	normal	baja	regla de candidato	normal	
BB TDA PV ATE	201987	31/08/2026	1380	720	0.92	0.97	-0.05	2	0	0	alza propia u_t>t	error	media	regla de candidato	error	
BB TDA SANTA CLARA	201985	27/07/2026	558	270	1.07	0.95	0.11	2	0	0	alza propia u_t>t	normal	baja	regla de candidato	normal	
BB TDA SUICRE	201987	10/08/2026	4080	2040	1	0.95	0.05	2	0	0	alza propia u_t>t	normal	media	regla de candidato	error	
BB TDA MINKA	201985	27/07/2026	606	297	1.04	0.93	0.11	2	0	0	alza propia u_t>t	normal	baja	regla de candidato	normal	
BB TDA PLAZA ESTA AMITA IN L	201985	27/07/2026	4080	2040	1	0.95	0.05	2	0	0	alza propia u_t>t	normal	media	regla de candidato	error	

y volvió a cargar con otra cantidad. Esta idea se descartó. Como indicó el asesor, cambiar una cantidad puede ser una decisión legítima de la tienda. Además, en 19 de las 23 líneas la cantidad corregida es mayor que la original (por ejemplo, de 18 a 72 unidades), lo que puede deberse tanto a un error de digitación como a que la tienda decidió pedir más. Estas líneas se tratarán como casos sospechosos que requieren evidencia.

También se observó que ninguna de estas correcciones sobresale en el total semanal, porque afectan a una sola línea. Por eso se agregó la comparación por línea descrita en la Sección 10.1.3.

10.6. Paso 4: el punto de partida que el modelo debe superar

Antes de entrenar el árbol de decisión se midieron tres reglas sencillas, para tener una cifra de referencia que el árbol deberá superar:

- R1.** Semana anterior: alerta si el pedido duplica el de la semana previa. Es lo más parecido a lo que hoy hace la analista.
- R2.** Habitual de la tienda: alerta si el pedido se aleja de lo que la tienda suele pedir más de lo que normalmente varía.
- R3.** Inusual sin ejemplos: un método (Isolation Forest) que marca pedidos poco comunes sin usar las etiquetas.

Las reglas se ajustaron con las semanas hasta el 10 de agosto y se compararon en el periodo de validación (17, 24 y 31 de agosto), que contiene 7 casos propuestos como posible error. La Tabla 32 muestra los resultados.

Tabla 32: Resultados de validación de las tres reglas. Los aciertos se cuentan frente a casos propuestos, no frente a errores confirmados.

Regla	Alertas	Aciertos	Alertas acertadas	Casos detectados	Alertas por semana
R1. Semana anterior	7	1	14 %	14 %	2,3
R2. Habitual de la tienda	11	5	45 %	71 %	3,7
R3. Inusual sin ejemplos	4	1	25 %	14 %	1,3
Meta del proyecto			70 % o más	80 % o más	2 a 5

La regla de la semana anterior coincidió con uno de los siete casos. Una semana previa baja genera falsas alarmas, y un error que se repite dos semanas, como el de ATE, deja de notarse en la segunda.

La regla de lo habitual de la tienda fue la más cercana a la meta y mantuvo un número de alertas manejable. Su problema aparece en la semana de Fiestas Patrias, con 34 alertas (Figura 16), porque no diferencia una tienda que sube sola de toda la cadena subiendo por el feriado. El árbol de decisión podría corregir esto, ya que dispone de la señal de movimiento común.

El método sin ejemplos casi no coincidió con los casos propuestos.

Estas cifras tienen limitaciones. Con 7 casos en validación, un acierto más o menos cambia el resultado en unos diez puntos. La regla que propone las etiquetas y la regla de lo habitual se parecen, lo que puede favorecer a esta última. Y se usaron semanas completas. Por eso el 45 % se toma solo como referencia para comparar el árbol.




Figura 15: Proporción de alertas acertadas (precisión) y de casos detectados (exhaustividad) en el periodo de validación. Las líneas punteadas indican las metas.




Figura 16: Número de alertas por semana de cada regla. La franja sombreada marca el volumen que el analista puede revisar; la línea vertical separa el periodo de ajuste del de validación.

10.7. Primera versión por pedido

Se programó una primera versión que evalúa cada línea en el momento de su registro, con las tres comparaciones de la Sección 10.1.3. Cada línea se compara solo con las semanas anteriores y con las líneas de la misma semana ya registradas. Los umbrales se fijaron con el periodo de ajuste, buscando unas cuatro alertas por semana, y se aplicaron sin cambios en validación.

Tabla 33: Versión por pedido en el periodo de validación. Una alerta corresponde a una tienda, producto y semana; se cuenta en la primera línea que la dispare.

Regla	Alertas por semana	Alertas acertadas	Casos detectados	Caso ATE detectado	Anticipación (días)
Acumulado de la semana frente a lo esperado	6,0	6 %	14 %	Sí	5
Tamaño de la línea frente a las anteriores	2,0	17 %	14 %	Sí	3
Cualquiera de las anteriores o línea duplicada	10,3	6 %	29 %	Sí	5




Figura 17: Precisión y exhaustividad de la versión por pedido en el periodo de validación.

regla	registro	fecha	anticipacion_dias	Tienda	Material	orden	pos	cant	q_ref	esperado_a_la_fecha	acum_semana	e_acum	a_1	u_acum	linea_tipica	r_linea	dup_previo
Acumulado de la semana	05/08/2026	10/08/2026	5	BB LA MOLINA - DARK KITCHEN	201986 4500723301	1240	90	690		30	90	2	0.03	1.97	120	0.75	FALSO
Acumulado de la semana	12/08/2026	17/08/2026	5	BB PULCP EXPRESS	201986 4500725226	1340	240	330		91.67	240	1.62	0.02	1.60	180	1.33	FALSO
Acumulado de la semana	12/08/2026	17/08/2026	5	BB PULCP EXPRESS	201987 4500725226	1350	420	600		171.43	420	1.45	0.03	1.42	300	1.40	FALSO
Acumulado de la semana	12/08/2026	17/08/2026	5	BB ROYAL PLAZA EXPRESS	201986 4500725226	1380	120	540		47.31	120	1.54	0.03	1.50	90	1.33	FALSO
Acumulado de la semana	17/07/2026	21/07/2026	4	BB TDA LARCO	201986 4500718907	260	300	2010		227.32	630	1.77	0.08	1.69	360	0.83	FALSO
Acumulado de la semana	17/07/2026	21/07/2026	4	BB TDA AV. PLAZ STA ANITA IN L	201985 4500718907	840	54	252		25.20	90	2.57	0.08	2.49	54	1	FALSO
Acumulado de la semana	17/07/2026	22/07/2026	5	BB TDA AV. PLAZ STA ANITA IN L	201987 4500718908	870	240	1140		253.33	720	1.84	0.08	1.76	240	1	FALSO
Acumulado de la semana	31/07/2026	04/08/2026	4	BB TDA AVIACION	201985 4500722064	630	198	1062		246.32	648	1.63	0.00	1.63	198	1	FALSO
Acumulado de la semana	31/07/2026	04/08/2026	4	BB TDA AVIACION	201986 4500722064	670	420	2415		672.29	1800	1.68	0.00	1.68	390	1.08	FALSO
Acumulado de la semana	31/07/2026	04/08/2026	4	BB TDA AVIACION	201987 4500722064	680	540	3240		861.85	2340	1.72	0.00	1.72	540	1	VERDADERO
Acumulado de la semana	17/07/2026	21/07/2026	4	BB TDA FC BEMBOS U LIMA	201985 4500718907	1300	36	144		18	54	2	0.08	1.92	36	1	FALSO
Acumulado de la semana	19/08/2026	24/08/2026	5	BB TDA FC BEMBOS U LIMA	201985 4500726892	1210	36	126		9.69	36	2.71	-0.05	2.76	18	2	FALSO
Acumulado de la semana	17/07/2026	21/07/2026	4	BB TDA FC BEMBOS U LIMA	201986 4500718907	1310	120	510		90	240	1.67	0.08	1.59	120	1	FALSO

Figura 18: Captura de la hoja alertas de salidas/05_alertas_pedido.xlsx: cada fila es una alerta emitida en la primera línea que la dispare, con su fecha de registro, su fecha de entrega y los días de anticipación.

Con la información disponible al alertar, la proporción de alertas acertadas baja del 45 % de la versión semanal a entre 6 % y 17 %, tal como advirtió el asesor. Parte de esa caída se debe a que la versión semanal conocía la semana completa. Otra parte se explica porque los casos sospechosos se definieron con semanas completas, lo que perjudica la comparación. Las tres variantes detectan el caso de ATE entre tres y cinco días antes de la entrega.

10.8. La brecha y la hipótesis de trabajo

En validación, el criterio que hoy aplica el área coincide con uno de cada siete casos sospechosos, la mejor regla sencilla con casi la mitad, y la meta es siete de cada diez. Para el paso siguiente se plantea la siguiente hipótesis:

Para el analista de planeamiento que revisa los pedidos de las 61 tiendas, un árbol de decisión que tenga en cuenta si toda la cadena se movió y si las tres presentaciones subieron juntas, usando solo información disponible al momento de alertar, elevará la proporción de alertas que coinciden con errores confirmados por encima de la mejor regla sencilla, manteniendo entre dos y cinco alertas por semana, en el periodo de prueba independiente.

Si el árbol no supera a la mejor regla sencilla en ese periodo, la hipótesis se rechaza y, tal como establece el hito del paso 5, la herramienta se construirá sobre esa regla, ajustada para reconocer las semanas en que toda la cadena se mueve.

10.9. Aprendizaje sobre la forma de trabajar

La revisión de casos, planificada como manual, pasó a ser asistida: el programa propone una etiqueta y la persona decide con evidencia. Para evitar que las propuestas se acepten sin revisarlas, en la semana 7 se registrará para cada caso la evidencia consultada y si la propuesta se mantuvo o se cambió. Si se cambia más del 30 %, se rehará la regla de propuesta; si se cambia menos del 5 %, se revisará una muestra con la analista.

10.10. Síntesis

Al cierre de la semana 6 se cuenta con un programa que limpia el archivo, calcula las señales de cada pedido, selecciona pedidos sospechosos y mide reglas sencillas. Comparar cada pedido con lo habitual de la tienda dio mejores resultados que compararlo con la semana anterior, aunque falla en semanas de campaña. Usando solo la información disponible al alertar, la precisión baja a entre 6 % y 17 %, y el caso de ATE se sigue detectando con tres a cinco días de anticipación. Son resultados preliminares, con pocas semanas y casos aún sin confirmar.

Para las semanas siguientes quedan tres condiciones, derivadas de la revisión del asesor: usar solo información disponible al alertar, confirmar cada error con evidencia y medir el resultado final en un periodo no usado para construir el método.

Referencias

- [1] Charu C. Aggarwal. *Outlier Analysis*. Springer, 2nd edition, 2017.
- [2] Scott W. Ambler and Mark Lines. *¡Eliza su WoW! Un enfoque de Disciplined Agile para optimizar su forma de trabajar*. Project Management Institute, 2.^a edition, 2023.
- [3] Leo Breiman, Jerome H. Friedman, Richard A. Olshen, and Charles J. Stone. *Classification and Regression Trees*. Wadsworth and Brooks/Cole, Monterey, CA, 1984.
- [4] Varun Chandola, Arindam Banerjee, and Vipin Kumar. Anomaly detection: A survey. *ACM Computing Surveys*, 41(3):15:1–15:58, 2009. Artículo 15.

- [5] Tianqi Chen and Carlos Guestrin. XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.
- [6] Victoria J. Hodge and Jim Austin. A survey of outlier detection methodologies. *Artificial Intelligence Review*, 22(2):85–126, 2004.
- [7] Rob J. Hyndman and George Athanasopoulos. *Forecasting: Principles and Practice*. OTexts, Melbourne, Australia, 3rd edition, 2021. <https://otexts.com/fpp3/>.
- [8] Kaoru Ishikawa. *Guide to Quality Control*. Asian Productivity Organization, Tokio, 2nd edition, 1986.
- [9] Hau L. Lee, V. Padmanabhan, and Seungjin Whang. Information distortion in a supply chain: The bullwhip effect. *Management Science*, 43(4):546–558, 1997.
- [10] Fei Tony Liu, Kai Ming Ting, and Zhi-Hua Zhou. Isolation forest. In *Proceedings of the 8th IEEE International Conference on Data Mining (ICDM)*, pages 413–422. IEEE, 2008.
- [11] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 4765–4774, 2017.
- [12] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [13] Project Management Institute. *The Standard for Project Management and A Guide to the Project Management Body of Knowledge (PMBOK Guide)*. Project Management Institute, Newtown Square, PA, 8th edition, 2025.
- [14] J. Ross Quinlan. *C4.5: Programs for Machine Learning*. Morgan Kaufmann, San Mateo, CA, 1993.
- [15] Rüdiger Wirth and Jochen Hipp. CRISP-DM: Towards a standard process model for data mining. *Proceedings of the 4th International Conference on the Practical Application of Knowledge Discovery and Data Mining*, pages 29–39, 2000.

A. Evidencias del prototipo

Este anexo documenta el prototipo construido en las semanas 1 a 6. Para cada paso se muestra el archivo de Excel que produce, tal como lo vería la analista de planeamiento, y la función del programa que lo genera. El prototipo se ejecuta con dos órdenes sobre el archivo exportado del sistema de compras, sin modificarlo:

```
python src/pipeline.py exportBIMBO.XLSX
python src/pedido.py exportBIMBO.XLSX [extracto_de_prueba.xlsx]
```

Tabla 34: Organización del prototipo.

Archivo	Función
src/pipeline.py	Pasos 1 a 4 en su versión semanal: limpieza, señales, casos sospechosos y reglas sencillas
src/pedido.py	Versión por pedido: señales con la información disponible al registrar cada línea, umbrales calibrados en el periodo de ajuste y métricas por periodo
src/figuras_gestion.py	EDT, diagrama de Gantt y matriz de riesgos
src/capturas_excel.ps1,	Generan las capturas de este anexo
src/capturas_codigo.py	
salidas/01 a 05_*.xlsx	Archivos de resultados de cada paso

A.1. Archivo de entrada

Fecha documento	Fe Entrega	Documento compras	Posición	Material	Texto breve	Historial pedido/Docu orden entrega	Por entregar (cantidad)	Unidad medida pedido	Nombre del proveedor	Creado por	Cantidad de pedido	Cantidad en UMA	Unidad de medida de almacén	Centro	Tienda	Indicador de borrado	Valor neto de pedido
4/09/2026	11/09/2026	4500730889	70	201985	BIMBO PAN HAMBURGUESA X18 UT		180.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		180.000	180.000 UN		2100	BB TDA MONTEERRICO		125.40
4/09/2026	11/09/2026	4500730889	70	201986	BIMBO PAN HAMBURGUESA X30 UT		330.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		330.000	330.000 UN		2100	BB TDA MONTEERRICO		193.60
4/09/2026	11/09/2026	4500730889	50	201987	BIMBO PAN HAMBURGUESA X60 UT		480.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		480.000	480.000 UN		2100	BB TDA MONTEERRICO		238.40
4/09/2026	11/09/2026	4500730889	70	201985	BIMBO PAN HAMBURGUESA X18 UT		144.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		144.000	144.000 UN		2101	BB TDA AURORA		100.32
4/09/2026	11/09/2026	4500730889	50	201986	BIMBO PAN HAMBURGUESA X30 UT		420.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		420.000	420.000 UN		2101	BB TDA AURORA		246.40
4/09/2026	11/09/2026	4500730889	50	201987	BIMBO PAN HAMBURGUESA X60 UT		420.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		420.000	420.000 UN		2101	BB TDA AURORA		208.60
4/09/2026	11/09/2026	4500730889	70	201986	BIMBO PAN HAMBURGUESA X30 UT		360.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		360.000	360.000 UN		2104	BB TDA LAS GARDENIAS		228.80
4/09/2026	11/09/2026	4500730889	50	201987	BIMBO PAN HAMBURGUESA X60 UT		600.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		600.000	600.000 UN		2104	BB TDA LAS GARDENIAS		298.00
4/09/2026	11/09/2026	4500730889	50	201985	BIMBO PAN HAMBURGUESA X18 UT		198.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		198.000	198.000 UN		2106	BB TDA JAVIER PRADO		137.94
4/09/2026	11/09/2026	4500730889	70	201986	BIMBO PAN HAMBURGUESA X30 UT		420.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		420.000	420.000 UN		2106	BB TDA JAVIER PRADO		246.40
4/09/2026	11/09/2026	4500730889	70	201987	BIMBO PAN HAMBURGUESA X60 UT		360.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		360.000	360.000 UN		2106	BB TDA JAVIER PRADO		178.80
4/09/2026	11/09/2026	4500730889	720	201985	BIMBO PAN HAMBURGUESA X18 UT		126.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		126.000	126.000 UN		2107	BB TDA JOCKEY PLAZA		87.76
4/09/2026	11/09/2026	4500730889	730	201986	BIMBO PAN HAMBURGUESA X30 UT		360.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		360.000	360.000 UN		2107	BB TDA JOCKEY PLAZA		211.20
4/09/2026	11/09/2026	4500730889	740	201987	BIMBO PAN HAMBURGUESA X60 UT		480.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		480.000	480.000 UN		2107	BB TDA JOCKEY PLAZA		238.40
4/09/2026	11/09/2026	4500730889	750	201985	BIMBO PAN HAMBURGUESA X18 UT		126.000 UN		2034873569 PANIFICADORA BIMBO VQUISPE		126.000	126.000 UN		2108	BB TDA ÓVALO GUTIÉRREZ		87.76

Figura 19: Archivo exportBIMBO.xlsx tal como se exporta del sistema de compras. Es la única entrada del prototipo.

A.2. Paso 1: limpieza

```

31 def limpiar(ruta):
32     d = pd.read_excel(ruta)
33     d = d.rename(columns={"Fe.Entrega": "fecha", "Cantidad de pedido": "cant",
34                          "Valor neto de pedido": "valor", "Documento compras": "orden",
35                          "Posición": "pos", "Indicador de borrado": "borrado"})
36     req = ["fecha", "Material", "Tienda", "cant", "valor", "orden", "pos", "borrado"]
37     falta = [c for c in req if c not in d.columns]
38     if falta:
39         raise SystemExit(f"No encuentro la(s) columna(s): {falta}")
40     d["semana"] = d["fecha"] - pd.to_timedelta(d["fecha"].dt.dayofweek, unit="D")
41     anul = d[d["borrado"] == "L"]
42     viva = d[d["borrado"] != "L"].copy()
43
44     # anuladas con reemplazo y cambio de cantidad -> etiquetas "rectificadas"
45     key = ["Tienda", "Material", "fecha"]
46     reemp = anul.merge(viva.sort_values(["orden", "pos"]).groupby(key)["cant"].first(),
47                       .rename("cant_final").reset_index(), on=key)
48     rectif = reemp[reemp["cant"] != reemp["cant_final"]].copy()
49
50     # duplicidad exacta entre líneas vigentes
51     viva["d_dup"] = viva.duplicated(key + ["cant"], keep=False).astype(int)
52     viva["precio_u"] = viva["valor"] / viva["cant"].replace(0, np.nan)
53     resumen = {"Filas_archivo": len(d), "anuladas": len(anul), "vigentes": len(viva),
54               "anuladas_con_reemplazo": len(reemp),
55               "rectificadas_cambio_cantidad": len(rectif),
56               "rectificada_mayor": int((rectif["cant_final"] > rectif["cant"]).sum()),
57               "rectificada_menor": int((rectif["cant_final"] < rectif["cant"]).sum()),
58               "líneas_duplicadas": int(viva["d_dup"].sum())}
59     return viva, rectif, resumen

```

Figura 20: Función limpiar (src/pipeline.py): verifica las columnas, separa las líneas anuladas, empareja cada anulada con su reemplazo y marca los duplicados.

	valor
filas_archivo	10772
anuladas	398
vigentes	10374
anuladas_con_reemplazo	385
rectificadas_cambio_cantidad	23
rectificada_mayor	19
rectificada_menor	4
lineas_duplicadas	119
series	180
observaciones_evaluables	1371
candidatos	78
error_propuesto	13
semanas_campana	13-07, 27-07

Fecha documento	fecha	Tienda	Material	orden	por	cant	cent_final	Texto breve	Historial pedido/Cocu-orden entr.
04/09/2026	08/09/2026	BB TDA LARCO II	201985	4500730884	430	108		126 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA STRIP LA MAR IN LINE	201985	4500730176	100	18		72 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA FC PLAZA SAN MIGUEL	201985	4500730176	110	18		54 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA FC PLAZA CENTER SMP REX	201985	4500730176	120	18		72 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA REAL PLAZA CHORILLOS	201986	4500730177	1660	30		120 BIMBO PAN HAMBURGUESA X30 UN BB MEDIANO	
02/09/2026	07/09/2026	BB TDA FC PLAZA CENTER SMP REX	201985	4500730177	1670	18		72 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA CAMINOS DEL INCA	201985	4500730177	1680	18		108 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA STRIP LA MAR IN LINE	201985	4500730177	1690	18		72 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA PV ATF	201985	4500730177	1700	18		36 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	07/09/2026	BB TDA FC PLAZA SAN MIGUEL	201985	4500730177	1710	18		54 BIMBO PAN HAMBURGUESA X18 UN BB GRANDE	
02/09/2026	05/09/2026	BB TDA SANTA CLARA	201987	4500730175	620	240		420 BIMBO PAN HAMBURGUESA X60 UN BB JUNIOR	

Figura 21: salidas/01_limpio.xlsx. A la izquierda, la hoja **resumen** con las cifras de limpieza; a la derecha, la hoja **rectificadas** con las líneas anuladas cuya cantidad cambió.

A.3. Paso 2: señales

```

78 def senales(s):
79     g = s.groupby(["Tienda", "Material"])["q"]
80     s["q_ref"] = g.transform(lambda x: x.shift(1).rolling(K, min_periods=2).median())
81     s["q_prev"] = g.shift(1)
82     mad = g.transform(lambda x: (x.shift(1).rolling(K, min_periods=2)
83                               .apply(lambda w: np.nanmedian(np.abs(w - np.nanmedian(w))), raw=True)))
84     s["e_t"] = (s["q"] - s["q_ref"]) / np.maximum(s["q_ref"], 1)
85     s["z_rob"] = (s["q"] - s["q_ref"]) / np.maximum(1.4826 * mad, 0.05 * s["q_ref"].clip(lower=1))
86     s["d_prev"] = (s["q"] - s["q_prev"]) / np.maximum(s["q_prev"], 1)
87     # peso del producto en el pedido de la tienda vs su peso histórico
88     tot = s.groupby(["Tienda", "semana"])["q"].transform("sum")
89     s["peso"] = s["q"] / tot
90     s["rho_mix"] = s["peso"] - s.groupby(["Tienda", "Material"])["peso"].transform(
91         lambda x: x.shift(1).rolling(K, min_periods=1).mean())
92     # factor común y residuo propio
93     s["a_t"] = s.groupby("semana")["e_t"].transform("median")
94     s["u_t"] = s["e_t"] - s["a_t"]
95     sube = (s["e_t"] > 0.3).astype(int)
96     s["c_sku"] = sube.groupby([s["Tienda"], s["semana"]]).transform("sum")
97     s["u_sig"] = s.groupby(["Tienda", "Material"])["u_t"].shift(-1)
98     ultima = s["semana"].max() # el extracto corta un viernes: semana incompleta
99     s["evaluable"] = s["q_ref"].notna() & s["q"].notna() & (s["semana"] < ultima)
100     return s

```

Figura 22: Función `senales` (src/pipeline.py): referencia de la tienda, desviación, variación semanal, peso del producto, movimiento común de la cadena y presentaciones en alza. El resultado se muestra en la Figura 12.

A.4. Paso 3: casos sospechosos

```

104 def candidatos(s, rectif):
105     ev = s[s["evaluable"]].copy()
106     rk = rectif.assign(semana=rectif["fecha"] - pd.to_timedelta(rectif["fecha"].dt.dayofweek, "D"))
107     rk = rk[["Tienda", "Material", "semana"]].drop_duplicates().assign(rectificada=1)
108     ev = ev.merge(rk, how="left", on=["Tienda", "Material", "semana"]).fillna({"rectificada": 0})
109     ev["campana"] = ev["a_t"] > KAPPA
110     ev["motivo_candidato"] = np.select(
111         [ev["d_dup"].eq(1) & ev["u_t"].gt(TAU), ev["d_dup"].eq(1), ev["u_t"].gt(TAU),
112          ev["u_t"].lt(-0.6)],
113         ["duplicidad + alza", "duplicidad", "alza propia u_t>τ", "caída fuerte"], default="")
114     c = ev[ev["motivo_candidato"] != ""].copy()
115     # propuesta de etiqueta, a confirmar con correos (columna 'etiqueta_final')
116     error = ((c["u_t"] > TAU) & ~c["campana"] & (c["c_sku"] < 3)) | \
117         ((c["d_dup"] == 1) & (c["e_t"] > 0.5))
118     c["etiqueta_propuesta"] = np.where(error, "error", "normal")
119     c["confianza"] = np.where((c["u_t"] > 1.5) | ((c["d_dup"] == 1) & (c["e_t"] > 0.5)), "alta",
120                               np.where(error, "media", "baja"))
121     c["fuente"] = "regla de candidato"
122     c.loc[c["Tienda"].eq("BB TDA PV ATE") & c["Material"].eq(201985) & c["semana"].eq("2026-08-17"),
123           ["etiqueta_propuesta", "confianza", "fuente"]] = ["error", "alta", "correo Fig. 3"]
124     c["etiqueta_final"] = c["etiqueta_propuesta"]
125     c["comentario_revisión"] = ""
126     ev = ev.merge(c[["Tienda", "Material", "semana", "etiqueta_final"]], how="left",
127                  on=["Tienda", "Material", "semana"])
128     ev["y"] = (ev["etiqueta_final"] == "error").astype(int)
129     return ev, c

```

Figura 23: Función `candidatos` (`src/pipeline.py`): selecciona los casos sospechosos, propone una etiqueta con su regla explícita y deja las columnas para la revisión con evidencia. El resultado se muestra en la Figura 14.

A.5. Paso 4: reglas sencillas

```

133 def reglas(ev):
134     semanas = sorted(ev["semana"].unique())
135     corte = semanas[-3] # validación temporal: últimas 3 semanas
136     tr, te = ev[ev["semana"] < corte], ev[ev["semana"] >= corte]
137     X = ["e_t", "z_rob", "d_prev", "rho_mix"]
138     iso = IsolationForest(n_estimators=300, contamination=max(tr["y"].mean(), 0.005),
139                          random_state=0).fit(tr[X].fillna(0))
140     pred = {
141         "R1 Semana anterior": lambda d: (d["d_prev"] > DPREV_UMBRA).astype(int),
142         "R2 Habitual de la tienda": lambda d: (d["z_rob"] > Z_UMBRA).astype(int),
143         "R3 Inusual sin ejemplos": lambda d: (iso.predict(d[X].fillna(0)) == -1).astype(int),
144     }
145     filas, semanal = [], []
146     for nom, f in pred.items():
147         for parte, d in [(("entrenamiento", tr), ("validación (3 últimas sem.)", te), ("total", ev))]:
148             p = f(d)
149             filas.append({"regla": nom, "conjunto": parte, "alertas": int(p.sum()),
150                          "errores_reales": int(d["y"].sum()),
151                          "aciertos": int((p & d["y"]).sum()),
152                          "precision": precision_score(d["y"], p, zero_division=0),
153                          "exhaustividad": recall_score(d["y"], p, zero_division=0),
154                          "f1": f1_score(d["y"], p, zero_division=0),
155                          "alertas_semana": p.sum() / d["semana"].nunique()})
156     ev[nom] = f(ev)
157     for nom in pred:
158         w = ev.groupby("semana").apply(lambda d: pd.Series({
159             "alertas": d[nom].sum(), "aciertos": (d[nom] & d["y"]).sum()), include_groups=False)
160         w["regla"] = nom
161         semanal.append(w.reset_index())
162     return pd.DataFrame(filas), pd.concat(semanal), list(pred), corte

```

Figura 24: Función `reglas` (`src/pipeline.py`): separa el periodo de ajuste del de validación y calcula, para cada regla, alertas, aciertos, precisión y exhaustividad.

regla	conjunto	alertas	errores_reales	aciertos	precision	exhaustividad	f1	alertas_semana
R1 Semana anterior	entrenamiento	19	6	2	0.11	0.33	0.16	3.80
R1 Semana anterior	validación (3 últimas sem.)	7	7	1	0.14	0.14	0.14	2.33
R1 Semana anterior	total	26	13	3	0.12	0.23	0.15	3.25
R2 Habitual de la tienda	entrenamiento	72	6	5	0.07	0.83	0.13	14.40
R2 Habitual de la tienda	validación (3 últimas sem.)	11	7	5	0.45	0.71	0.56	3.67
R2 Habitual de la tienda	total	83	13	10	0.12	0.77	0.21	10.38
R3 Inusual sin ejemplos	entrenamiento	6	6	2	0.33	0.33	0.33	1.20
R3 Inusual sin ejemplos	validación (3 últimas sem.)	4	7	1	0.25	0.14	0.18	1.33
R3 Inusual sin ejemplos	total	10	13	3	0.30	0.23	0.26	1.25

Figura 25: Hoja metrices de salidas/04_reglas.xlsx, origen de la Tabla 32.

A.6. Versión por pedido

```

34 def senales_por_linea(viva):
35     """Señales calculadas en el instante de registro de cada línea (sin mirar al futuro)."""
36     v = viva.rename(columns={"Fecha documento": "registro"}).sort_values(
37         ["registro", "orden", "pos"].reset_index(drop=True))
38     v["anticipacion_dias"] = (v["fecha"] - v["registro"]).dt.days
39     filas = []
40     for (t, m), g in v.groupby(["Tienda", "Material"], sort=False):
41         reg, sem, cant = g["registro"].values, g["semana"].values, g["cant"].values
42         fechas = g["fecha"].values
43         for i in range(len(g)):
44             conocido = reg[i]
45             conocido[i + 1:] = np.arange(i + 1, len(g)) < i + 1 # mismo día: solo las anteriores
46             # referencia: mediana de totales de las 4 semanas previas, con lo ya registrado
47             previas = conocido & (sem < sem[i])
48             tot = pd.Series(cant[previas]).groupby(sem[previas]).sum().sort_index()
49             semanas_ref = tot.iloc[-P.K:] if len(tot) >= 2 else None
50             ref = float(np.median(semanas_ref)) if semanas_ref is not None else np.nan
51             # acumulado hasta el día de entrega de esta línea, contra lo que la tienda suele
52             # llevar acumulado a ese día de la semana (perfil de semanas previas)
53             dia = (fechas - sem).astype("timedelta64[D]").astype(int)
54             acum = cant[conocido & (sem == sem[i]) & (dia <= dia[i])].sum()
55             if semanas_ref is not None:
56                 prev_w = pd.DataFrame({"w": sem[previas], "d": dia[previas], "c": cant[previas]})
57                 tot_w = prev_w.groupby("w")["c"].sum()
58                 prev_w = prev_w[prev_w["d"] <= dia[i]].groupby("w")["c"].sum()
59                 share = float(np.median((hasta.reindex(tot_w.index, fill_value=0) / tot_w).iloc[-P.K:]))
60             else:
61                 share = np.nan
62                 lineas_prev = cant[previas]
63                 med_linea = np.median(lineas_prev) if len(lineas_prev) >= 3 else np.nan
64                 dup = bool(((cant == cant[i]) & (fechas == fechas[i]) & conocido
65                     & ((np.arange(len(g)) != i).any()))
66                 filas.append((g.index[i], ref, ref * share if share != share else np.nan, acum, med_linea, dup))
67     f = pd.DataFrame(filas, columns=["idx", "q_ref", "esperado_a_la_fecha", "acum_semana", "linea_tipica", "dup_previo"]).set_index("idx")
68     v = v.join(f)
69     v["e_acum"] = (v["acum_semana"] - v["esperado_a_la_fecha"]) / np.maximum(v["esperado_a_la_fecha"], 1)
70     v["r_linea"] = v["cant"] / v["linea_tipica"]
71     # movimiento común: mediana de e_acum de las líneas de esa semana registradas hasta ese día
72     v["a_t"] = np.nan
73     for w, g in v.groupby("semana"):
74         orden = g.sort_values("registro")
75         v.loc[orden.index, "a_t"] = orden["e_acum"].expanding().median().values
76     v["e_acum"] = v["e_acum"] - v["a_t"]
77     v["evaluable"] = v["q_ref"].notna() & (v["semana"] < v["semana"].max())
78     v["periodo"] = periodo(v["semana"])
79     return v

```

Figura 26: Función `senales_por_linea` (`src/pedido.py`): para cada línea usa solo lo registrado hasta ese día. La referencia sale de semanas anteriores y el acumulado se compara con lo que la tienda suele llevar a esa fecha.

```

82 def calibrar(v, objetivo=4.0):
83     """Umbral más bajo que en el periodo de AJUSTE deja <= objetivo alertas por semana."""
84     a = v[(v["evaluable"] & (v["periodo"] == "ajuste"))]
85     n_sem = a["semana"].nunique()
86     key = ["Tienda", "Material", "semana"]
87     umbrales = {}
88     for col, base in [("u_acum", None), ("r_linea", None)]:
89         x = a.loc[a["a_t"] <= P.KAPPA].groupby(key)[col].max().dropna()
90         cand = np.sort(x.values)[-1:]
91         umbrales[col] = float(cand[int(objetivo * n_sem)]) if len(cand) > objetivo * n_sem else float(cand[-1])
92     return umbrales

```

Figura 27: Función `calibrar` (`src/pedido.py`): fija los umbrales solo con el periodo de ajuste, para unas cuatro alertas por semana.

regla	período	semanas	alertas	sospechosos	aciertos	precisión	exhaustividad	confirmados_detectados	anticipacion_mediana_dias	alertas_semana
Acumulado de la semana	ajuste	5	20	6	2	0.10	0.33 0/0		5	4
Acumulado de la semana	validación	3	18	7	1	0.06	0.14 1/1		5	6
Tamaño de la línea	ajuste	5	14	6	1	0.07	0.17 0/0		5	2.80
Tamaño de la línea	validación	3	6	7	1	0.17	0.14 1/1		3	2
Cualquiera o duplicado	ajuste	5	60	6	6	0.10	1 0/0		5	12
Cualquiera o duplicado	validación	3	31	7	2	0.06	0.29 1/1		5	10.33

Figura 28: Hoja `metricas_por_periodo` de `salidas/05_alertas_pedido.xlsx`, origen de la Tabla 33. La columna `confirmados_detectados` muestra que el caso ATE se detecta en validación.